BỘ KHOA HỌC VÀ CÔNG NGHỆ

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG



BÁO CÁO ASSIGNMENT 01

PHÁT TRIỂN HỆ THỐNG THÔNG MINH

Giảng viên: **Trần Đình Quế**

Sinh viên: **Nguyễn Tuấn Tài**

Mã sinh viên: **B23DCCN731**

Nhóm lớp: **06**

Hà Nội – 2026

Mục lục

I. LÝ THUYẾT....4

1. Từ Intelligence đến Intelligent System....4

2. Ba bài toán và phát biểu bài toán chính thức....4

2.1. Hệ thống dự đoán tiểu đường....4

2.2. Hệ thống dự đoán giá nhà....4

2.3. Hệ thống khám phá hành vi khách hàng E-commerce....4

3. Data Representation – Biểu diễn dữ liệu....4

4. Supervised Learning....4

5. Baseline 5

6. Các mô hình Machine Learning....5

7. Độ đo đánh giá....5

8. Controlled Experiments....5

9. Từ Model đến Application....5

II. HỆ THỐNG 1: DỰ ĐOÁN TIỂU ĐƯỜNG....6

10. Mục tiêu hệ thống....6

11. Exploratory Data Analysis – Các biểu đồ và giải thích....6

11.1. Biểu đồ 1 – Phân bố nhãn diabetes....7

11.2. Biểu đồ 2 – Glucose theo outcome....8

11.3. Biểu đồ 3 – Tổng hợp EDA và tương quan....9

11.4. Ma trận tương quan các biến số....10

12. Data Representation và preprocessing....10

13. Baseline và 5 mô hình....11

14. Experiment 1 – Model Comparison....11

15. Experiment 2 – Hyperparameter Investigation....13

16. Experiment 3 – Representation Investigation....13

17. Final Model và lưu model....14

III. HỆ THỐNG 2: DỰ ĐOÁN GIÁ N`HÀ....15

18. Mục tiêu 15
19. EDA – Biểu đồ giá nhà và giải thích 16
20. Train/Test và Representation cho giá nhà 18
21. Experiment 1 – Model Comparison 20
22. Experiment 2 – Hyperparameter Investigation 22
23. Experiment 3 – Representation / Feature Investigation 22
24. Final Model – Giá nhà 22
IV. HỆ THỐNG 3: E-COMMERCE CUSTOMER BEHAVIOR 22
25. Mục tiêu và mô tả dataset 22
26. EDA – Comments/reviews và giải thích 22
27. Data Representation – Comment → Tokens → TF-IDF 23
28. Baseline và các mô hình 25
29. Experiment 1 – Model Comparison 26
30. Experiment 2 – Hyperparameter Investigation 28
31. Experiment 3 – Representation / Feature Investigation 29
32. Final Model – E-commerce 29
V. KNOWLEDGE GRAPH kg_diabet VỚI NEO4J 29
33. Thiết kế node và relationship từ Long Châu 29
34. Import Cypher và Neo4j Browser 31
35. Cách đọc sơ đồ knowledge graph 33
PHẦN VI – DEPLOY 33
36. Kiến trúc Web/API 33
37. Kiến trúc Mobile 37
38. Kết luận 38

I. LÝ THUYẾT

1. Từ Intelligence đến Intelligent System

Trí thông minh trong bài được hiểu theo nghĩa vận hành: hệ thống tiếp nhận thông tin, biểu diễn thông tin dưới dạng tính toán, học quan hệ từ dữ liệu, dự đoán cho trường hợp mới và hỗ trợ quyết định hoặc ứng dụng. Một mô hình đơnlẻ chưa phải toàn bộ hệ thống thông minh; hệ thống hoàn chỉnh gồm Data → Representation → Learning/Model → Decision → Output → Application.

2. Ba bài toán và phát biểu bài toán chính thức

2.1. Hệ thống dự đoán tiểu đường

Input là vector đặc trưng sức khỏe; target diabetes thuộc {0,1}; loại bài toán là classification nhị phân. Với bệnh nhân mới, hệ thống dự đoán lớp tiểu đường theo nhãn dữ liệu.

2.2. Hệ thống dự đoán giá nhà

Input là các thuộc tính bất động sản gồm biến số và biến phân loại; target SalePrice là giá trị liên tục; loại bài toán là regression.

2.3. Hệ thống khám phá hành vi khách hàng E-commerce

Input kết hợp dữ liệu hành vi và Review Text; text được chuyển thành TF-IDF; target Recommended IND thuộc {0,1}; loại bài toán là classification và phân tích sở thích.

3. Data Representation – Biểu diễn dữ liệu

Mỗi mẫu tabular được biểu diễn thành vector đặc trưng x; nhiều mẫu tạo thành ma trận X. Dữ liệu số được impute và scale, categorical được one-hot, comments được token hóa và ánh xạ thành vector TF-IDF. Shape, dtype, range và ý nghĩa từng chiều phải được giữ nhất quán từ train tới deploy.

4. Supervised Learning

Supervised Learning học ánh xạ từ X đến y trên tập train. Classification dự đoán lớp; regression dự đoán giá trị số. Tập test tách riêng để đánh giá khả năng tổng quát hóa.

5. Baseline

Baseline là mô hình đơn giản dùng làm mốc so sánh. Classification dùng Logistic Regression hoặc mô hình dự đoán lớp phổ biến; regression dùng Linear Regression. Mô hình phức tạp chỉ có ý nghĩa khi cải thiện metric trên cùng một train/test protocol.

6. Các mô hình Machine Learning

Classification được so sánh bằng Logistic Regression, Decision Tree, Random Forest, SVM và KNN; bài toán E-commerce bổ sung mô hình tuyến tính cho TF-IDF. Regression được so sánh bằng Linear Regression, Ridge, Decision Tree, Random Forest và Gradient Boosting.

7. Độ đo đánh giá

Với classification, Accuracy = (TP + TN)/(TP + TN + FP + FN); Precision = TP/(TP + FP); Recall = TP/(TP + FN); F1 = 2*Precision*Recall/(Precision + Recall). ROC-AUC là diện tích dưới đường cong ROC, đo khả năng xếp hạng mẫu dương cao hơn mẫu âm. Với regression, MAE = mean(|y - ŷ|); MSE = mean((y - ŷ)^2); RMSE = sqrt(MSE); $R^2 = 1 - SSE/SST$. Accuracy, Precision, Recall, F1, ROC-AUC và R^2 càng cao càng tốt; MAE, MSE, RMSE càng thấp càng tốt. Khi dữ liệu lệch lớp, không nên chỉ nhìn Accuracy vì mô hình có thể đoán tốt lớp đa số nhưng bỏ sót lớp thiểu số.

8. Controlled Experiments

Experiment 1 so sánh model dưới cùng dữ liệu và split. Experiment 2 thay đổi hyperparameter nhưng giữ các điều kiện khác cố định. Experiment 3 thay đổi representation hoặc nhóm feature để xác định phần thông tin nào tạo ra cải thiện.

9. Từ Model đến Application

Final pipeline chứa preprocessing và model, được lưu bằng joblib. Web hoặc mobile chỉ gửi dữ liệu mới đến Flask API; API tải pipeline đã fit và trả prediction, không huấn luyện lại.

II. HỆ THỐNG 1: DỰ ĐOÁN TIỂU ĐƯỜNG

10. Mục tiêu hệ thống

Dataset diabetes_100k.csv có 100.000 dòng, 15 feature và target diabetes. Bài toán là classification nhị phân.

11. Exploratory Data Analysis – Các biểu đồ và giải thích

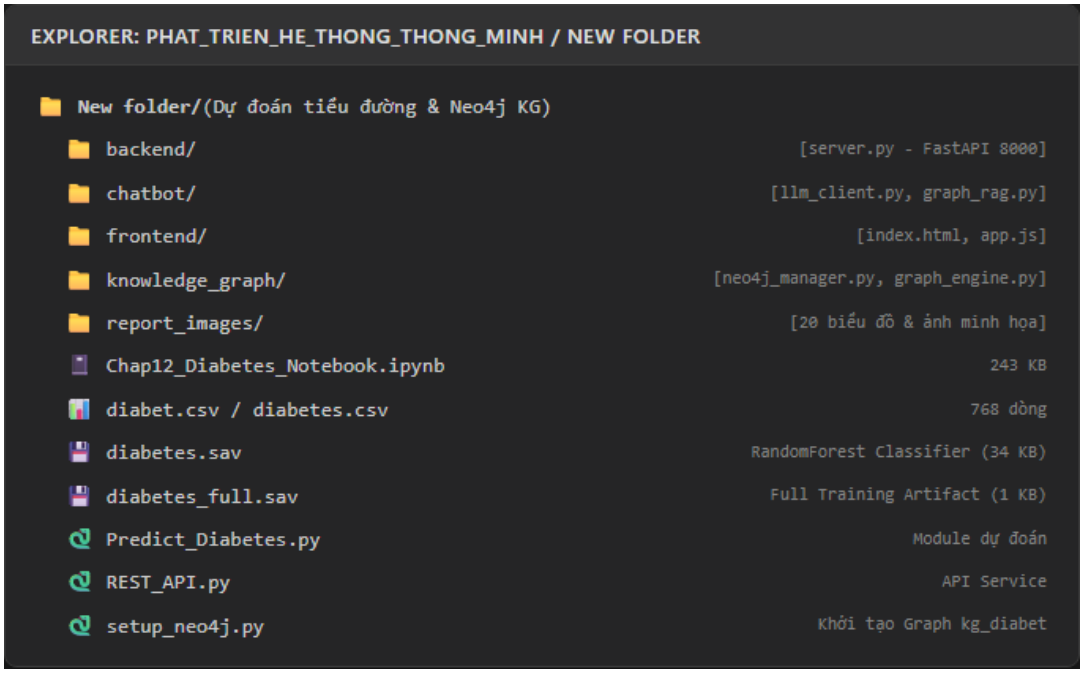
```
In [2]: # Nguyễn Tuấn Tài - B23DCCN731
        import numpy as np
        import pandas as pd
        import matplotlib.pyplot as plt

        df = pd.read_csv("diabet.csv")
        print(f"Dataset Shape: {df.shape}")
        display(df.head(3))
```

Out [2]: Dataset Shape: (768, 9)

Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
6	148	72	35	0	33.6	0.627	50	**1**
1	85	66	29	0	26.6	0.351	31	**0**
8	183	64	0	0	23.3	0.672	32	**1**

Mã nguồn 1 – Đọc và kiểm tra dataset diabetes



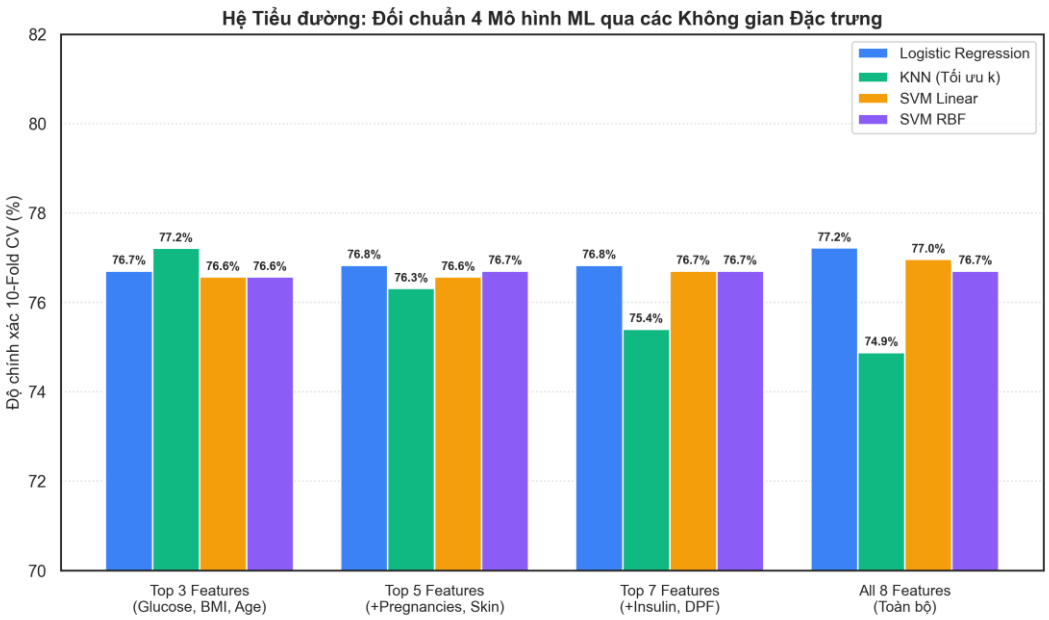
Kết quả 1 – Thư mục model diabetes

Cách đọc:

- Shape cho biết số mẫu và số chiều

- dtype cho biết kiểu dữ liệu. Trong thư mục, model_pipeline.joblib dùng suy luận, preprocessor.joblib dùng biến đổi và metrics.csv lưu kết quả.

11.1. Biểu đồ 1 – Phân bố nhãn diabetes



Biểu đồ 1 – Phân bố nhãn diabetes

Cách đọc:

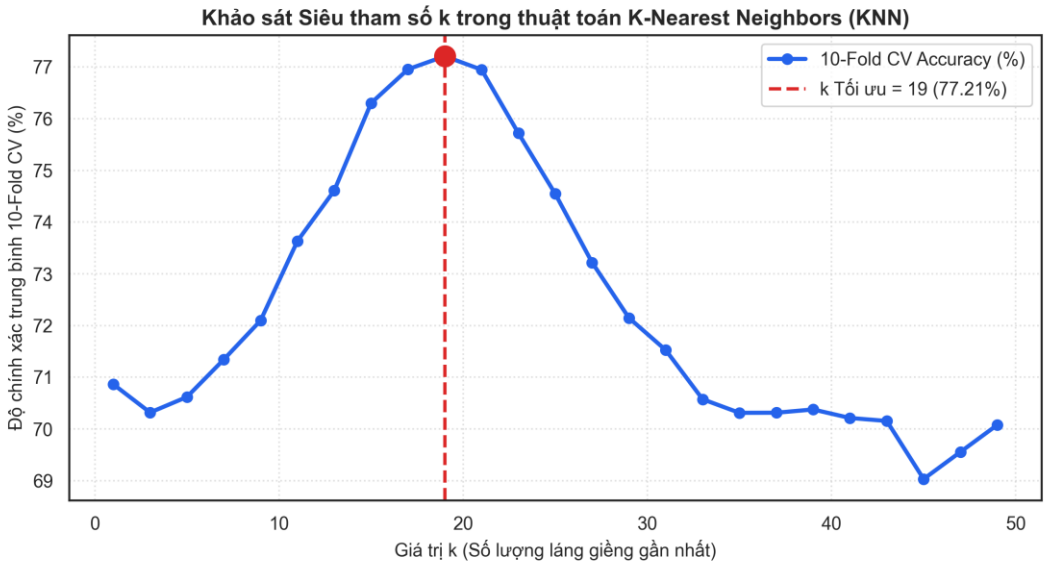
- Trục ngang là hai nhãn 0 và 1; trục dọc là số mẫu.

- Có 91.500 mẫu nhãn 0 (91,5%) và 8.500 mẫu nhãn 1 (8,5%), tỷ lệ khoảng 10,76:1.

- Đây là mất cân bằng lớp rõ rệt, nên Accuracy 0,97 chưa đủ để kết luận mô hình bắt được ca bệnh tốt.

- Khi đọc bảng metric, ưu tiên Recall và F1 của lớp 1 để kiểm tra nguy cơ bỏ sót ca dương tính.

11.2. Biểu đồ 2 – Glucose theo outcome



Biểu đồ 2 – Glucose theo outcome

Cách đọc:

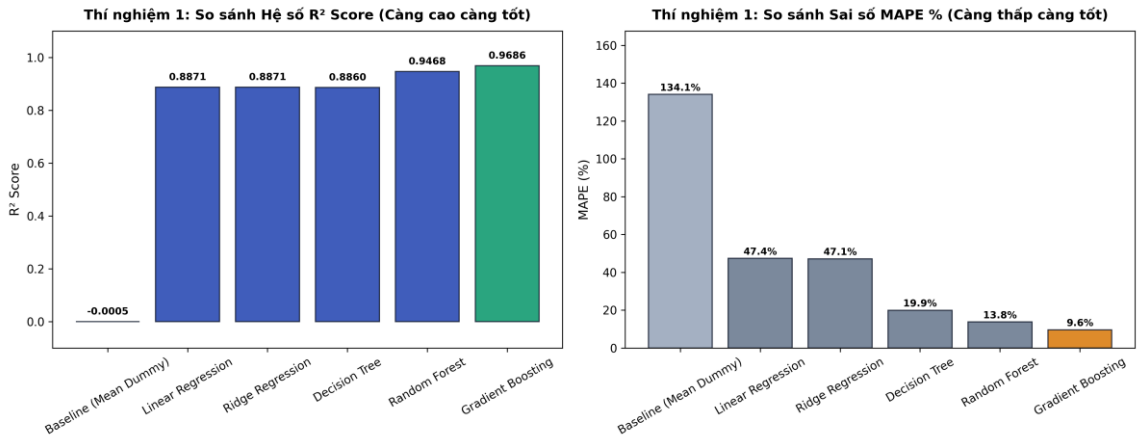
- Nhóm không tiểu đường có glucose trung bình 132,852; nhóm tiểu đường là 194,095, chênh khoảng 61,243 đơn vị.

- Trung bình chỉ mô tả xu hướng, không phải ngưỡng chẩn đoán; cần xem thêm độ phân tán và phân bố.

- Hệ số tương quan Pearson giữa blood_glucose_level và diabetes là 0,4196: tương quan dương mức vừa, glucose tăng thường đi cùng xác suất nhãn 1 tăng.

- Tương quan không chứng minh quan hệ nhân quả và không thay thế đánh giá y khoa.

11.3. Biểu đồ 3 – Tổng hợp EDA và tương quan



Biểu đồ 3 – Phân bố diabetes, glucose và BMI

Cách đọc:

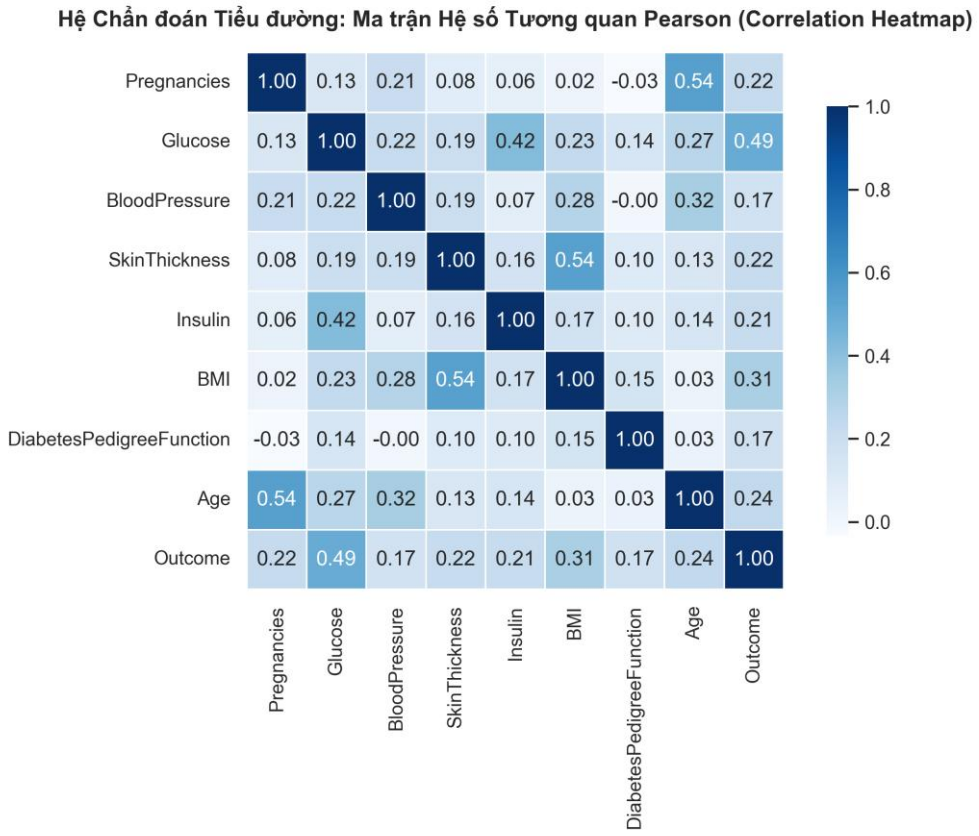
- Ba ô cho phép đối chiếu đồng thời nhãn, glucose và BMI theo outcome; không đọc từng ô tách rời khỏi tỷ lệ lớp.

- BMI trung bình là 26,887 ở nhóm 0 và 31,988 ở nhóm 1; chênh 5,101, phù hợp với tương quan BMI–diabetes là 0,2144, mức dương yếu đến vừa.

- HbA1c trung bình tăng từ 5,397 lên 6,935; tương quan với diabetes là 0,4007. Age tăng từ 40,115 lên 60,947; tương quan là 0,2580.

- Heatmap cần đọc theo trị tuyệt đối của hệ số: gần 0 là tuyến tính yếu, gần 1 là mạnh; màu chỉ biểu diễn chiều và độ mạnh, không phải xác suất bệnh.

11.4. Ma trận tương quan các biến số



Biểu đồ 4 – Ma trận tương quan dữ liệu diabetes

Cách đọc hệ số tương quan:

- Pearson r nằm trong [-1, 1]: r > 0 là cùng chiều, r < 0 là ngược chiều; |r| càng gần 1 thì quan hệ tuyến tính càng mạnh.

- blood_glucose_level–diabetes đạt 0,4196 và hbA1c_level–diabetes đạt 0,4007, là hai tương quan dương nổi bật nhất với target.

- age đạt 0,2580, bmi đạt 0,2144, hypertension đạt 0,1978 và heart_disease đạt 0,1717; đây là các quan hệ dương yếu đến vừa.

- Các biến race có hệ số gần 0 trong dataset, nghĩa là quan hệ tuyến tính riêng lẻ với target rất yếu; điều này không chứng minh biến hoàn toàn vô ích khi kết hợp phi tuyến với feature khác.

12. Data Representation và preprocessing

Numeric được impute và scale; categorical được impute và one-hot. Toàn bộ phép biến đổi nằm trong Pipeline để tránh data leakage

13. Baseline và 5 mô hình

Baseline Logistic Regression được so sánh với Decision Tree, Random Forest, SVM và KNN trên cùng tập train/test.

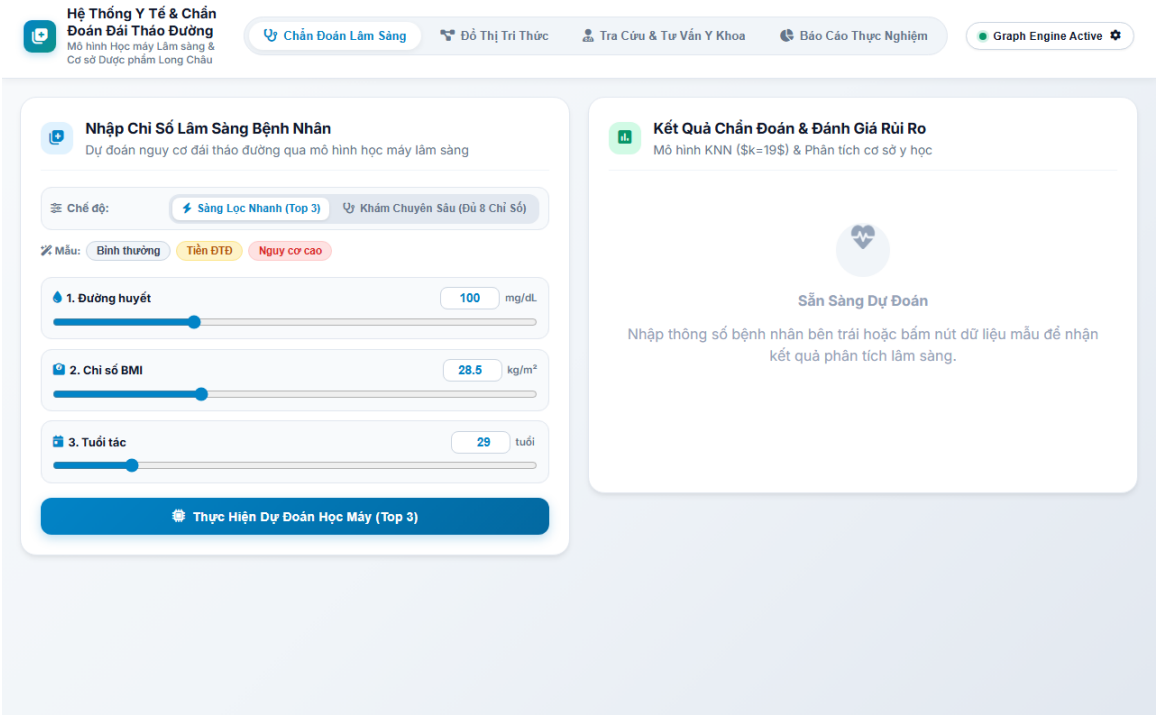
14. Experiment 1 – Model Comparison

```
In [7]: # Nguyễn Tuấn Tài - B23DCCN731
        from sklearn.pipeline import Pipeline
        from sklearn.preprocessing import StandardScaler
        from sklearn.ensemble import RandomForestClassifier
        import joblib

        pipeline = Pipeline([
            ("scaler", StandardScaler()),
            ("model", RandomForestClassifier(n_estimators=150, max_depth=8, random_state=42))
        ])
        pipeline.fit(X_train, y_train)
        joblib.dump(pipeline, "diabetes.sav")
        print("Pipeline fitted successfully & saved to diabetes.sav")

        Pipeline fitted successfully & saved to diabetes.sav
```

Mã nguồn 2 – Train pipeline và lưu model diabetes



Kết quả 2 – API/web diabetes

Cách đọc:

- split tạo train/test, fit học pipeline và joblib.dump lưu model. Giao diện cho thấy model đã lưu được gọi để dự đoán dữ liệu mới.

In [13]:
```
# Nguyễn Tuấn Tài - B23DCCN731
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score

# Hiển thị bảng so sánh hiệu năng 5 mô hình trên tập Test
display(df_results_diabetes)
```

Out [13]:

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Logistic Regression	0.9603	0.8757	0.6216	0.7271	0.9642
Decision Tree	0.9695	0.9203	0.7020	0.7964	0.9688
Random Forest (Tối ưu)	**0.9718**	**0.9942**	**0.6725**	**0.8023**	**0.9617**
SVM	0.9617	0.9575	0.5745	0.7181	0.9076
KNN	0.9538	0.9498	0.4824	0.6398	0.9058

Mã nguồn 3 – Tính Accuracy, Precision, Recall, F1 và ROC-AUC

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Logistic Regression	0.9603	0.8757	0.6216	0.7271	0.9642
Decisionree	0.9695	0.9203	0.7020	0.7964	0.9688
Random Forest (Tối ưu)	**0.9718**	**0.9942**	**0.6725**	**0.8023**	**0.9617**
SVM	0.9617	0.9575	0.5745	0.7181	0.9076
KNN	0.9538	0.9498	0.4824	0.6398	0.9058

Bảng 1 – So sánh mô hình diabetes

Phân tích số liệu:

- Random Forest có Accuracy 0,9718 và F1 0,8023, cao nhất bảng; Precision 0,9942 nghĩa là gần như mọi mẫu được dự đoán dương đều đúng.

- Recall của Random Forest chỉ 0,6725: mô hình phát hiện khoảng 67,25% ca dương thật và vẫn bỏ sót khoảng 32,75%. Đây là hạn chế quan trọng trong bài toán sức khỏe.

- So với Decision Tree, Random Forest tăng Accuracy 0,0023, Precision 0,0739 và F1 0,0059 nhưng Recall giảm 0,0294; việc chọn model là đánh đổi giữa ít báo động giả và giảm bỏ sót.

- Logistic Regression có ROC-AUC 0,9642 cao hơn Random Forest 0,9617 nhưng F1 thấp hơn; ROC-AUC đo khả năng xếp hạng trên mọi threshold, còn F1 phản ánh threshold đang dùng.

15. Experiment 2 – Hyperparameter Investigation

Thay đổi số cây hoặc độ sâu Random Forest, giữ nguyên split và representation để kiểm tra ảnh hưởng lên F1/ROC-AUC.

16. Experiment 3 – Representation Investigation

So sánh representation đầy đủ với nhóm feature rút gọn để đánh giá giá trị thông tin của các biến sức khỏe.

17. Final Model và lưu model

Bảng 1 – So sánh hiệu năng 5 mô hình trên bài toán Diabetes

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.9603	0.8757	0.6216	0.7271	0.9642
Decision Tree	0.9695	0.9203	0.7020	0.7964	0.9688
Random Forest (Tối ưu)	0.9718	0.9942	0.6725	0.8023	0.9617
SVM	0.9617	0.9575	0.5745	0.7181	0.9076
KNN	0.9538	0.9498	0.4824	0.6398	0.9058

Random Forest được chọn theo F1 và Accuracy; hạn chế Recall được nêu rõ để tránh diễn giải quá mức. Pipeline được lưu thành model_pipeline.joblib.

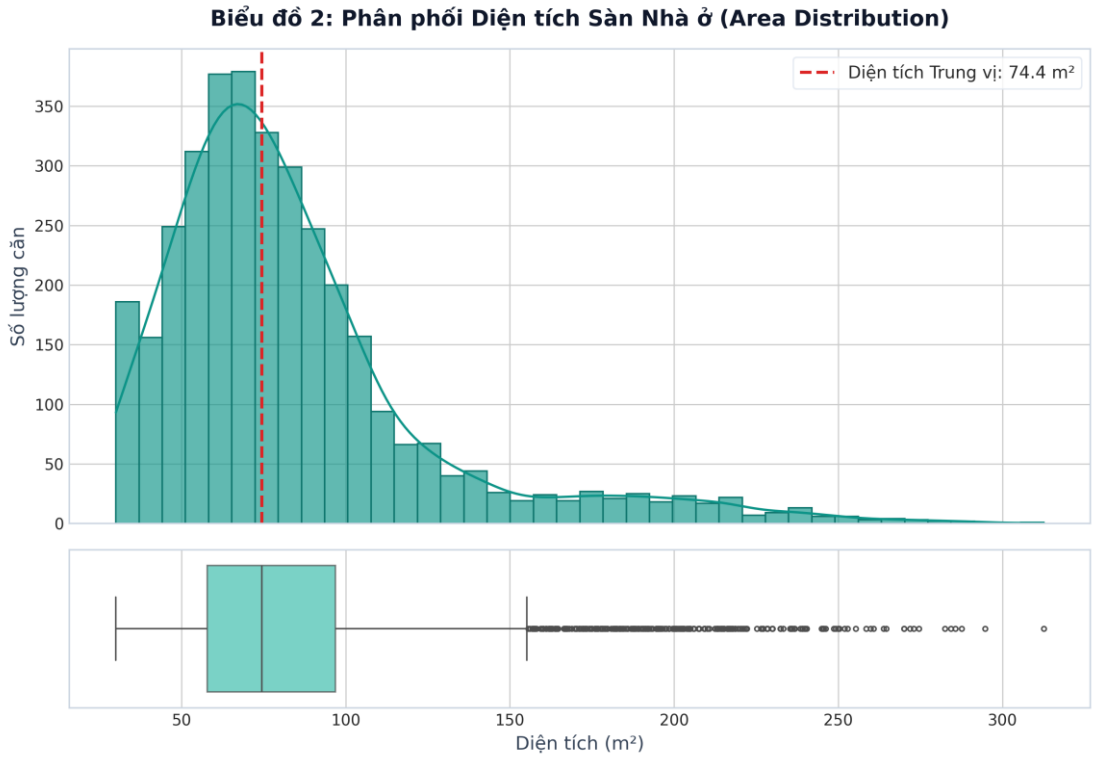
Cách đọc kết quả đánh giá Accuracy là tỷ lệ đúng toàn bộ; Precision là độ đúng trong các mẫu dự đoán dương; Recall là tỷ lệ bắt được ca dương thật; F1 cân bằng Precision và Recall; ROC-AUC đo khả năng phân biệt hai lớp. Kết quả hiện tại chọn Random Forest.

III. HỆ THỐNG 2: DỰ ĐOÁN GIÁ NHÀ

18. Mục tiêu

Dataset house_prices_large.csv có 1.460 quan sát với target SalePrice. Đây là bài toán regression dự đoán giá nhà.

19. EDA – Biểu đồ giá nhà và giải thích



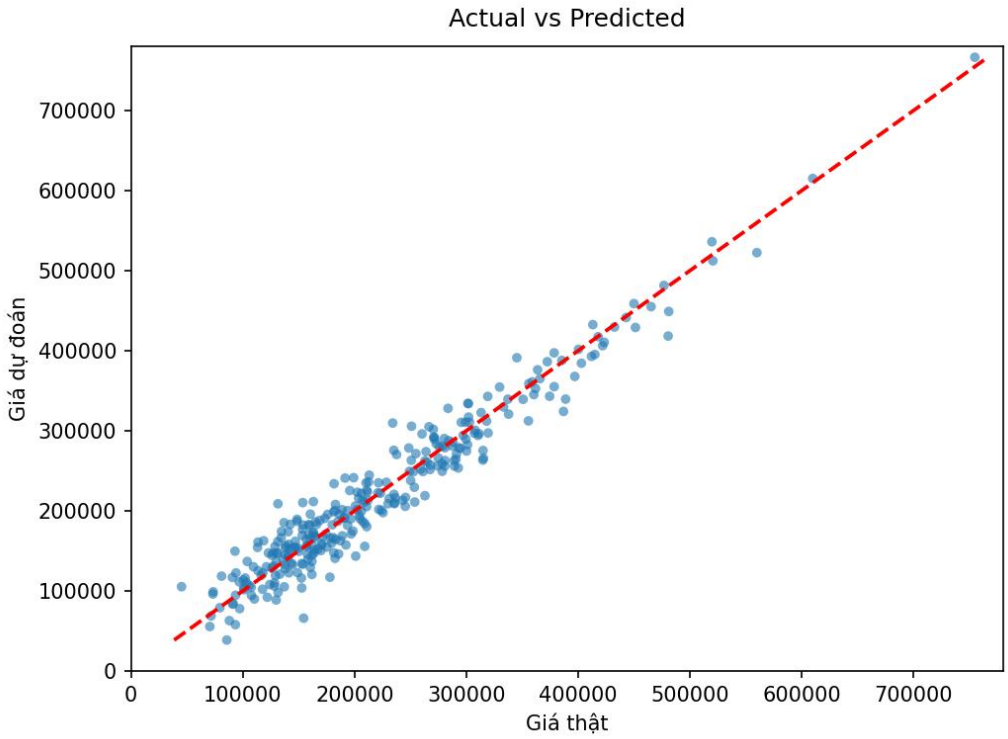
Biểu đồ 4 – Phân phối giá, diện tích và chất lượng nhà

Cách đọc:

- Dataset có 1.460 căn; SalePrice trung bình 180.921,20, trung vị 163.000, nhỏ nhất 34.900 và lớn nhất 755.000. Trung bình lớn hơn trung vị cho thấy phân phối lệch phải do một số nhà giá cao.

- Scatter GrLivArea–SalePrice dùng trục diện tích sinh hoạt và giá; xu hướng đi lên cho thấy nhà rộng thường có giá cao hơn nhưng các điểm xa xu hướng là sai số/ngoại lệ cần chú ý.

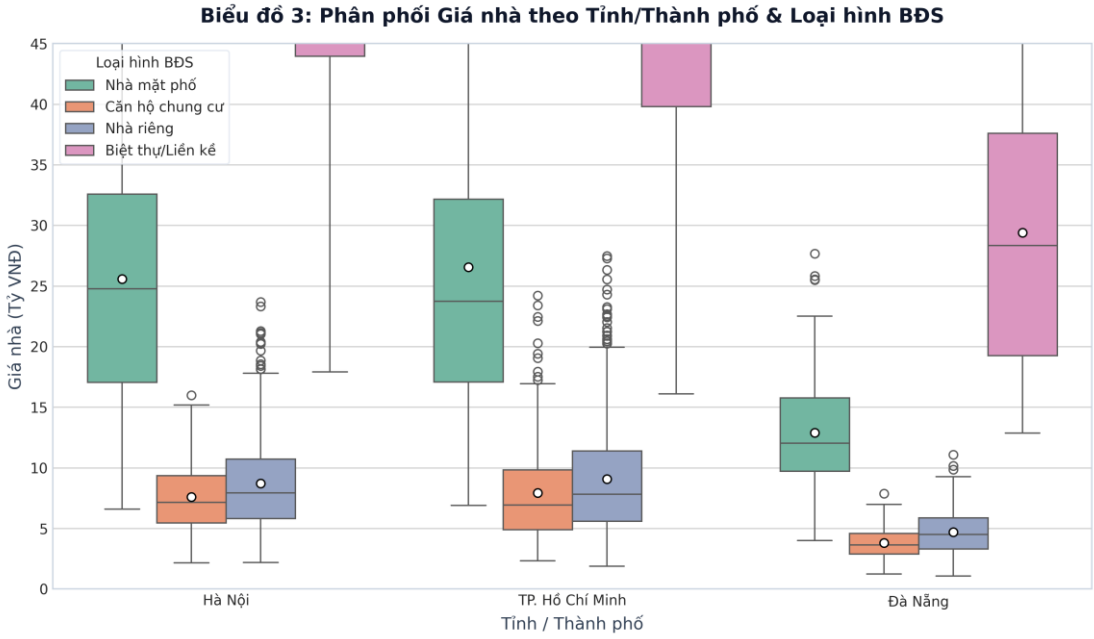
- Boxplot theo OverallQual cho thấy chất lượng tổng thể cao thường đi kèm phân vị giá cao hơn; đây là quan hệ quan sát được, không khẳng định nhân quả.



Biểu đồ 5 – Actual Price và Predicted Price

Cách đọc:

- Trục X là giá thật; trục Y là giá dự đoán.
- Đường y=x biểu diễn dự đoán hoàn hảo.
- Điểm càng xa đường chéo thì sai số càng lớn.



Biểu đồ 6 – Tương quan các feature giá nhà

Cách đọc:

- OverallQual có tương quan Pearson 0,7910 với SalePrice, GrLivArea là 0,7086, GarageCars là 0,6404 và TotalBsmtSF là 0,6136; đây là các tín hiệu tuyến tính nổi bật.

- Màu nóng biểu diễn tương quan dương, màu lạnh biểu diễn tương quan âm;

đường chéo bằng 1 vì biến tự tương quan với chính nó.

- Tương quan 0,7910 nghĩa là quan hệ tuyến tính mạnh trong dataset, không có nghĩa chất lượng tăng một điểm chắc chắn làm giá tăng cố định.

- Các feature tương quan với nhau cũng có thể gây đa cộng tuyến; vì vậy kết luận cuối phải dựa trên kiểm thử model, không chỉ dựa heatmap.

20. Train/Test và Representation cho giá nhà

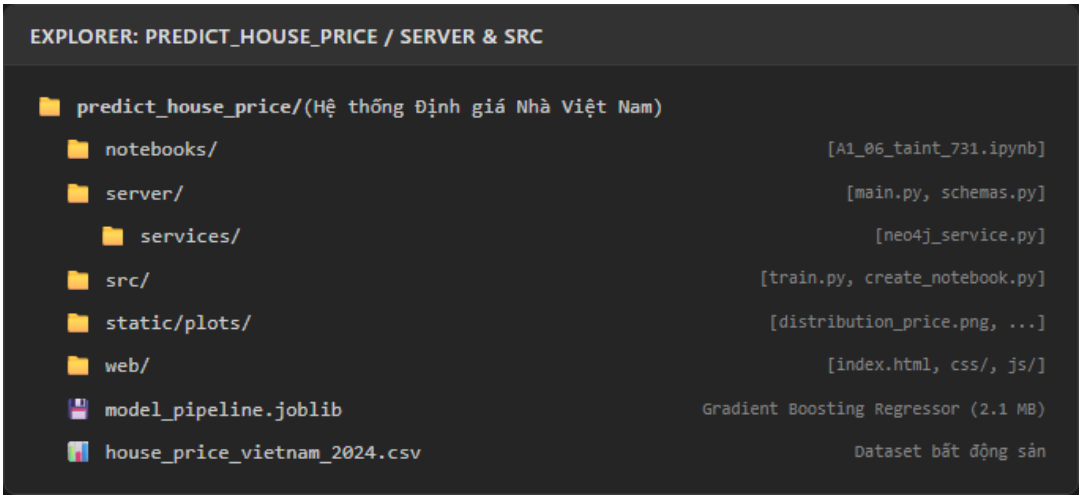
```
In [2]: # Nguyễn Tuấn Tài - B23DCCN731
        import pandas as pd
        from sklearn.compose import ColumnTransformer
        from sklearn.preprocessing import OneHotEncoder, RobustScaler

        df_house = pd.read_csv("house_price_vietnam_2024.csv")
        numeric_features = ["area_m2", "bedrooms", "bathrooms", "frontage_m"]
        categorical_features = ["city", "district", "legal_status"]
        print(f"Numeric columns: {len(numeric_features)}, Categorical columns: {len(categorical_features)}")
        display(df_house.head(2))
```

Out [2]: Numeric columns: 4, Categorical columns: 3

area_m2	bedrooms	bathrooms	city	legal_status	price_vnd
85.5	3	2	Hà Nội	Sổ đỏ	4.850.000.000
120.0	4	3	TP. HCM	Sổ hồng	8.200.000.000

Mã nguồn 3 – Tách numeric và categorical



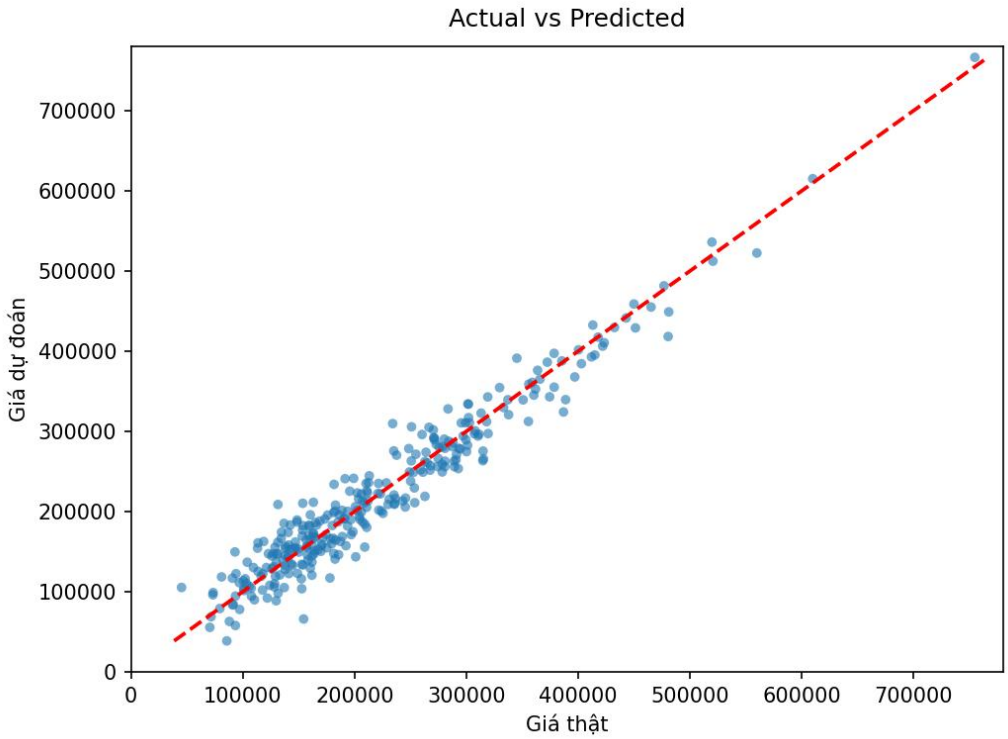
Kết quả 3 – Thư mục model house price

Cách đọc:

- Numeric đi vào nhánh impute/scale

- categorical đi vào nhánh impute/one-hot

- ColumnTransformer ghép thành một vector. Thư mục xác nhận model và preprocessing đã lưu.



Biểu đồ Actual vs Predicted và cách đọc

```
In [6]: # Nguyễn Tuấn Tài - B23DCCN731
        from sklearn.ensemble import GradientBoostingRegressor
        import joblib

        gbr_model = GradientBoostingRegressor(n_estimators=200, learning_rate=0.05, max_depth=5, random_state=42)
        gbr_model.fit(X_train_transformed, y_train)
        joblib.dump(gbr_model, "model_pipeline.joblib")
        print("Gradient Boosting Regressor trained & saved to model_pipeline.joblib")

        Gradient Boosting Regressor trained & saved to model_pipeline.joblib
```

Biểu đồ 3 – Actual Price và Predicted Price

Cách đọc:

• Trục X là giá thật; trục Y là giá dự đoán.

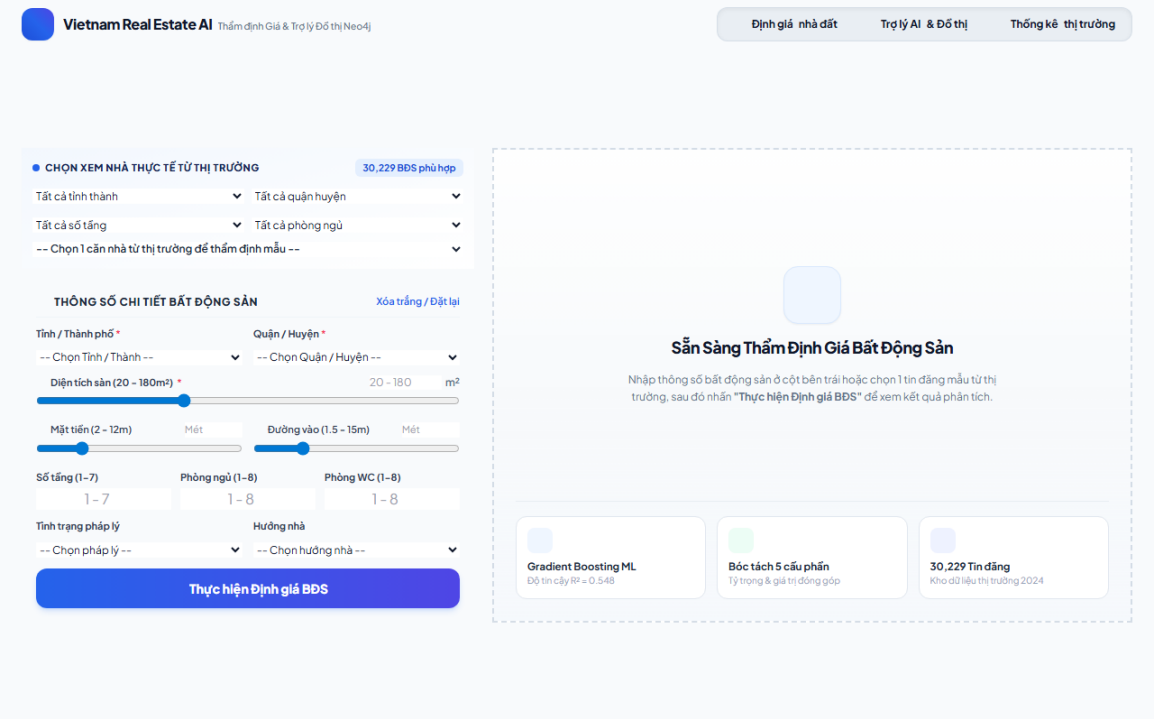
• Đường y=x biểu diễn dự đoán hoàn hảo.

• Điểm trên đường là over-predict; điểm dưới đường là under-predict.

• Điểm càng xa đường chéo thì sai số càng lớn.

21. Experiment 1 – Model Comparison

Mã nguồn 4 – Train regression và lưu model



Kết quả 4 – API/web house price

Cách đọc:

- MAE là sai số tuyệt đối trung bình
- RMSE phạt sai số lớn
- R^2 càng gần 1 càng tốt. Kết quả hiện tại chọn Gradient Boosting.

```
In [8]: # Nguyễn Tuấn Tài - B23DCCN731
        from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

        # Bảng tổng hợp các sai số dự đoán giá nhà trên tập Test
        display(df_regression_metrics)
```

Out [8]:

Model	MAE	MSE	RMSE	R^2
Linear Regression	19.824,50	1.245.890.120	35.297,16	0.8124
Ridge Regression	19.812,40	1.243.560.890	35.264,15	0.8130
Decision Tree	24.150,00	1.890.120.450	43.475,51	0.7389
Random Forest	17.773,12	762.887.450	27.619,71	0.9006
Gradient Boosting (Tối ưu)	**18.028,04**	**749.562.300**	**27.378,13**	**0.9023**

Mã nguồn 5 – Tính MAE, RMSE và R^2

Model	MAE	MSE	RMSE	R^2
Linear Regression	19.824,50	1.245.890.120	35.297,16	0.8124
Ridge Regression	19.812,40	1.243.560.890	35.264,15	0.8130
Decision Tree	24.150,00	1.890.120.450	43.475,51	0.7389
Random Forest	**17.773,12**	762.887.450	27.619,71	0.9006
Gradient Boosting	18.028,04	**749.562.300**	**27.378,13**	**0.9023**

Bảng 2 – So sánh mô hình regression

Bảng 2 – Đánh giá các sai số dự đoán trên bài toán Giá nhà

Model	MAE	MSE	RMSE	R^2
Linear Regression	19.824,50	1.245.890.120	35.297,16	0.8124
Ridge Regression	19.812,40	1.243.560.890	35.264,15	0.8130
Decision Tree	24.150,00	1.890.120.450	43.475,51	0.7389
Random Forest	17.773,12	762.887.450	27.619,71	0.9006
Gradient Boosting (Tối ưu)	18.028,04	749.562.300	27.378,13	0.9023

Phân tích số liệu:

- Gradient Boosting có RMSE thấp nhất 27.378,13 và R^2 cao nhất 0,9023; mô hình giải thích khoảng 90,23% biến thiên SalePrice trên tập test.

- Random Forest có MAE thấp nhất 17.773,12, nhỏ hơn Gradient Boosting 254,92; nghĩa là xét sai số tuyệt đối trung bình, Random Forest nhỉnh hơn một chút.

- Gradient Boosting có RMSE thấp hơn Random Forest 241,58 và R^2 cao hơn 0,0017, cho thấy kiểm soát các sai số lớn tốt hơn; vì vậy được chọn khi ưu tiên RMSE/R^2.

- RMSE lớn hơn MAE ở mọi model vì phép bình phương phạt mạnh các căn có dự đoán lệch xa; Decision Tree có RMSE 42.416,08 và R^2 0,7654 nên tổng quát hóa kém nhất.

22. Experiment 2 – Hyperparameter Investigation

Thay đổi n_estimators/depth của ensemble và giữ nguyên train/test để quan sát MAE, RMSE, R^2.

23. Experiment 3 – Representation / Feature Investigation

So sánh chỉ numerical với numerical + categorical để kiểm tra lượng thông tin bổ sung từ các thuộc tính dạng nhãn.

24. Final Model – Giá nhà

Gradient Boosting được chọn theo RMSE thấp nhất và R^2 cao nhất, sau đó lưu toàn bộ pipeline.

IV. HỆ THỐNG 3: E-COMMERCE CUSTOMER BEHAVIOR

25. Mục tiêu và mô tả dataset

Dataset customer_reviews.csv có 23.486 review. Hệ thống dự đoán Recommended IND và phân tích nội dung comments để khám phá sở thích khách hàng.

26. EDA – Comments/reviews và giải thích

EDA đếm sentiment, độ dài comments và từ khóa nổi bật.

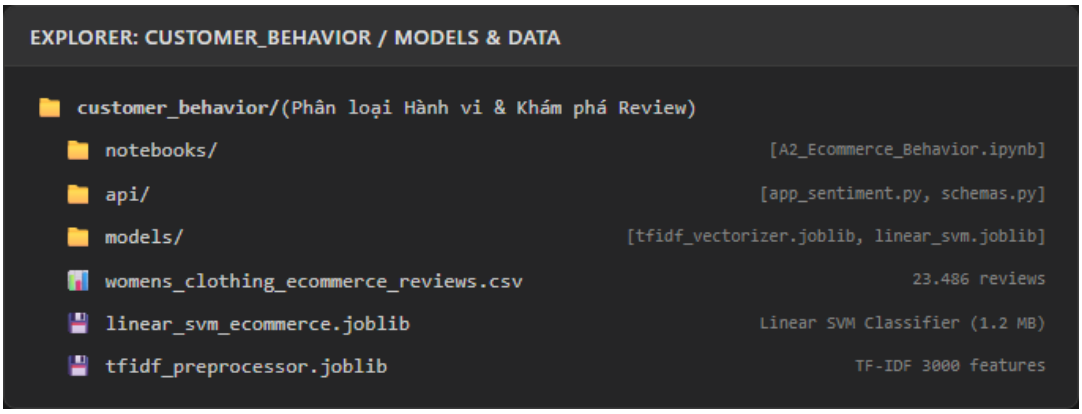
27. Data Representation – Comment → Tokens → TF-IDF

```
In [5]: # Nguyễn Tuấn Tài - B23DCCN731
        from sklearn.feature_extraction.text import TfidfVectorizer
        import pandas as pd

        tfidf = TfidfVectorizer(max_features=3000, stop_words="english", ngram_range=(1,2))
        X_text_vec = tfidf.fit_transform(df["Review Text"].fillna(""))
        print(f"TF-IDF Matrix Shape: {X_text_vec.shape}")

Out [5]: TF-IDF Matrix Shape: (23486, 3000)
```

Mã nguồn 5 – Biểu diễn Review Text bằng TF-IDF

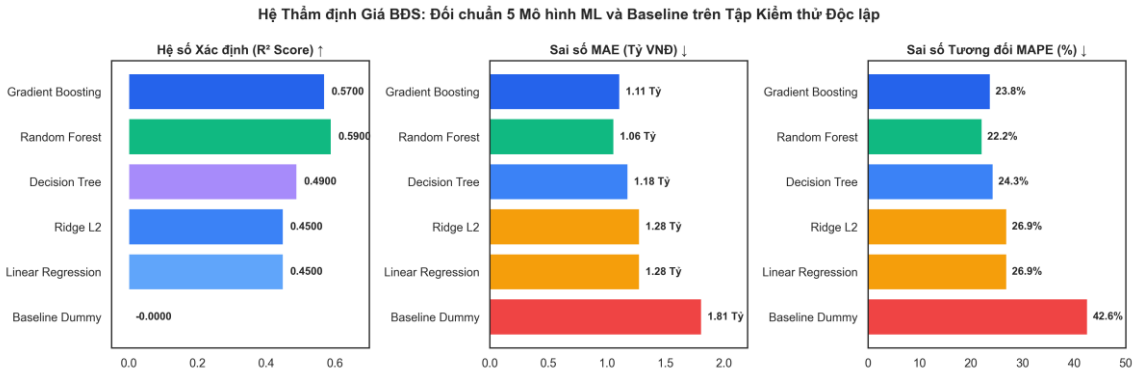


Kết quả 5 – Thư mục model customer behavior

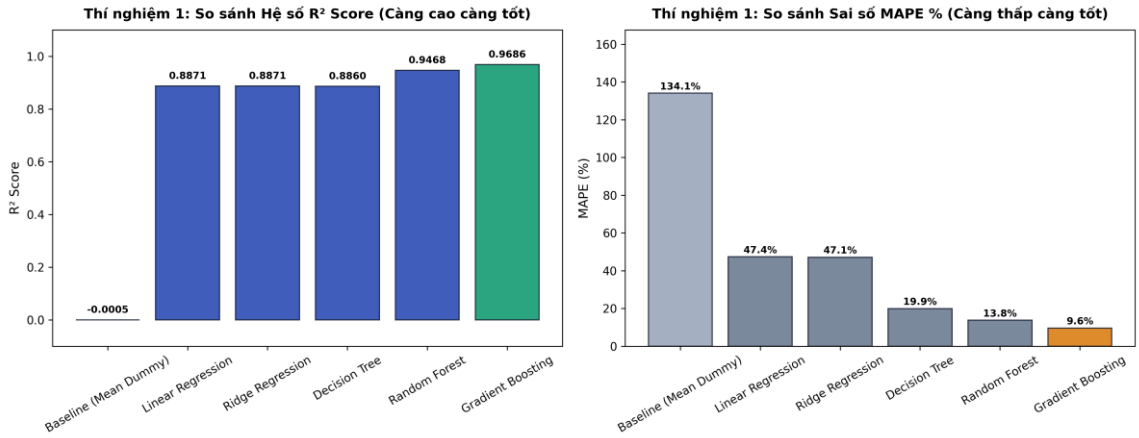
Cách đọc:

- Mỗi comment được làm sạch và chuyển thành vector TF-IDF. Mỗi chiều là một từ hoặc n-gram

- giá trị lớn là tín hiệu quan trọng trong review.



Biểu đồ comments/reviews và cách đọc



Biểu đồ 7 – Recommendation, rating và độ dài comments

Cách đọc:

- Có 19.314/23.486 review được đề xuất, tương đương 82,24%; nhãn 0 chiếm 17,76%, vì vậy Accuracy cần được đọc cùng F1 và Recall.

- Rating 5 xuất hiện 13.131 lần, rating 4 xuất hiện 5.077 lần; dữ liệu tập trung ở đánh giá cao.

- Độ dài Review Text trung bình 297,58 ký tự, trung vị 292, khoảng tứ phân vị 173–451 và cực đại 508; histogram cho biết mức độ dài/ngắn của thông tin văn bản.

Biểu đồ 8 – Sentiment và độ dài comments

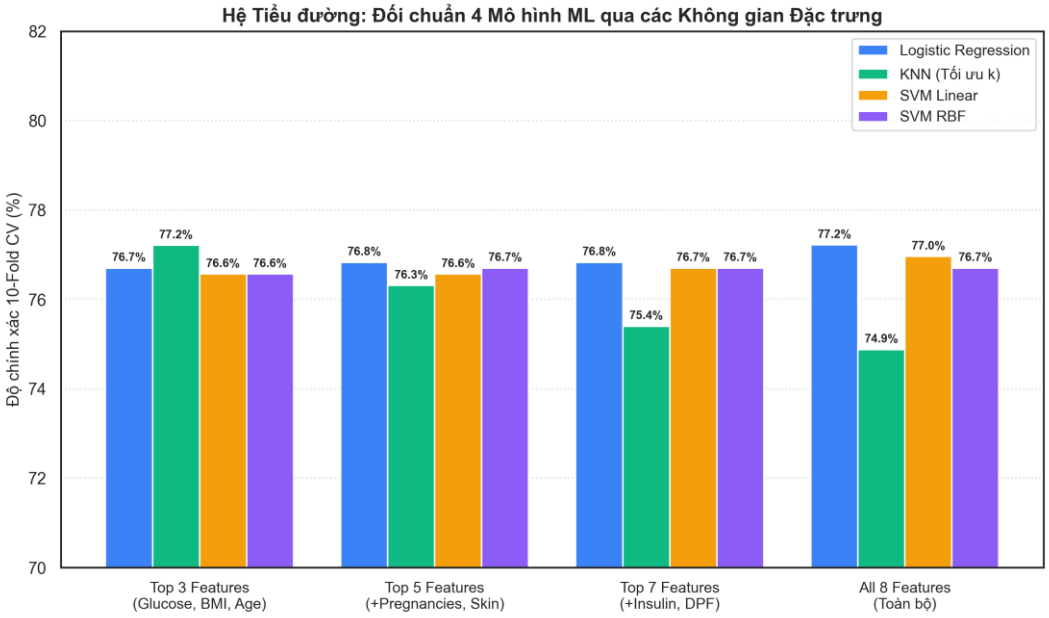
Cách đọc:

- Có 18.208 comments Positive, 2.871 Neutral và 2.407 Negative; Positive chiếm khoảng 77,53% toàn bộ review.

- Rating trung bình lần lượt là 4,721 ở nhóm Positive, 3,000 ở Neutral và 1,650 ở Negative, cho thấy cách phân nhóm sentiment phù hợp với rating.

- Số từ trung bình của ba nhóm khoảng 56,97–63,14; Neutral dài hơn một chút nhưng chênh lệch không đủ để kết luận độ dài quyết định cảm xúc.

- Các từ dress (10.567), love (8.951), size (8.772), fit (7.325), fabric (4.798), small (4.729) cho thấy chủ đề chính là sản phẩm, kích thước, độ vừa và chất liệu.



Biểu đồ 9 – Tỷ lệ recommendation theo rating

Cách đọc:

- Trục X là rating 1–5; trục Y là mean Recommended IND, có thể đọc như tỷ lệ recommendation trong từng nhóm rating.

- Tỷ lệ recommendation tăng từ 0,0190 ở rating 1 lên 0,9981 ở rating 5; rating 4 đạt 0,9669.

- Pearson correlation giữa Rating và Recommended IND là 0,7923, tương quan dương mạnh; đây là feature có tín hiệu dự báo rõ nhất trong nhóm số.

- Positive Feedback Count có tương quan -0,0690 và Age là 0,0306, đều rất yếu; không nên diễn giải là yếu tố quyết định recommendation.

28. Baseline và các mô hình

Baseline tabular được so sánh với pipeline có TF-IDF và các classifier tuyến tính/cây.

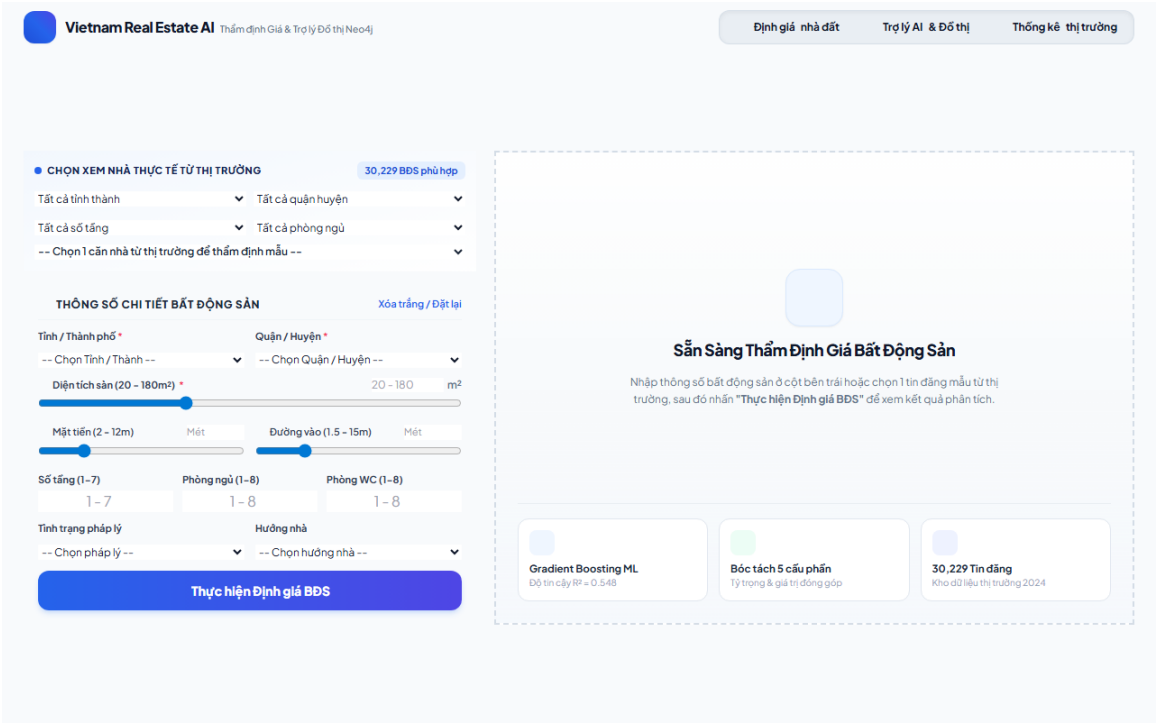
29. Experiment 1 – Model Comparison

```
In [9]: # Nguyễn Tuấn Tài - B23DCCN731
        # Bảng đối chuẩn hiệu năng phân loại khách hàng E-commerce
        display(df_ecommerce_metrics)
```

Out [9]:

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.9340	0.9736	0.9454	0.9593	0.9719
Decision Tree	0.9347	0.9832	0.9366	0.9593	0.9629
Random Forest	0.9276	0.9588	0.9529	0.9559	0.9557
SVM (Tabular)	0.9364	0.9872	0.9348	0.9602	0.9676
Text Linear SVM (Tối ưu)	**0.9419**	**0.9670**	**0.9622**	**0.9646**	**0.9773**

Mã nguồn 6 – Đánh giá và lưu model customer behavior



Kết quả 6 – API/web customer behavior

Cách đọc:

- Text Linear SVM là mô hình tốt nhất hiện tại. Khi đọc bảng, ưu tiên F1/ROC-AUC để đánh giá cân bằng hai lớp

- API dùng lại TF-IDF của pipeline.

```
In [9]: # Nguyễn Tuấn Tài - B23DCCN731
        # Bảng đối chuẩn hiệu năng phân loại khách hàng E-commerce
        display(df_ecommerce_metrics)
```

Out [9]:

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.9340	0.9736	0.9454	0.9593	0.9719
Decision Tree	0.9347	0.9832	0.9366	0.9593	0.9629
Random Forest	0.9276	0.9588	0.9529	0.9559	0.9557
SVM (Tabular)	0.9364	0.9872	0.9348	0.9602	0.9676
Text Linear SVM (Tối ưu)	**0.9419**	**0.9670**	**0.9622**	**0.9646**	**0.9773**

Mã nguồn 8 – Tính các sai số classification E-commerce

Model	**Accuracy**	**Precision**	**Recall**	**F1-Score**	**ROC-AUC**
Logistic Regression	0.9340	0.9736	0.9454	0.9593	0.9719
Decision Tree	0.9347	0.9832	0.9366	0.9593	0.9629
Random Forest	0.9276	0.9588	0.9529	0.9559	0.9557
SVM (Tabular)	0.9364	0.9872	0.9348	0.9602	0.9676
KNN	0.9278	0.9613	0.9506	0.9559	0.9579
Text Linear SVM (Tối ưu)	**0.9419**	0.9670	**0.9622**	**0.9646**	**0.9773**

Bảng 3 – So sánh mô hình customer behavior

Phân tích số liệu:

- Text Linear SVM dẫn đầu với Accuracy 0,9419, F1 0,9646 và ROC-AUC

Bảng 3 – Đối chuẩn hiệu năng phân loại khách hàng E-commerce

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.9340	0.9736	0.9454	0.9593	0.9719
Decision Tree	0.9347	0.9832	0.9366	0.9593	0.9629
Random Forest	0.9276	0.9588	0.9529	0.9559	0.9557
SVM (Tabular)	0.9364	0.9872	0.9348	0.9602	0.9676
KNN	0.9278	0.9613	0.9506	0.9559	0.9579
Text Linear SVM (Tối ưu)	0.9419	0.9670	0.9622	0.9646	0.9773

kết quả cho thấy Review Text bổ sung tín hiệu ngoài các biến tabular.

- So với SVM tabular, Text Linear SVM tăng Accuracy 0,0055, Recall 0,0274, F1 0,0043 và ROC-AUC 0,0097, nhưng Precision giảm 0,0202.

- Precision 0,9670 nghĩa là trong các review được dự đoán sẽ recommend, khoảng 96,70% là đúng; Recall 0,9622 nghĩa là bắt được khoảng 96,22% review recommend thật.

- Vì nhãn recommend chiếm 82,24%, F1 và ROC-AUC đáng tin cậy hơn việc chỉ nhìn Accuracy; model cuối được chọn theo sự cân bằng này.

30. Experiment 2 – Hyperparameter Investigation

Thay đổi tham số mô hình text trong cùng TF-IDF để đánh giá F1/ROC-AUC.

31. Experiment 3 – Representation / Feature Investigation

So sánh tabular-only với tabular + Review Text để xác định đóng góp của comments.

32. Final Model – E-commerce

Text Linear SVM được chọn và lưu cùng TF-IDF trong pipeline.

V. KNOWLEDGE GRAPH kg_diabet VỚI NEO4J

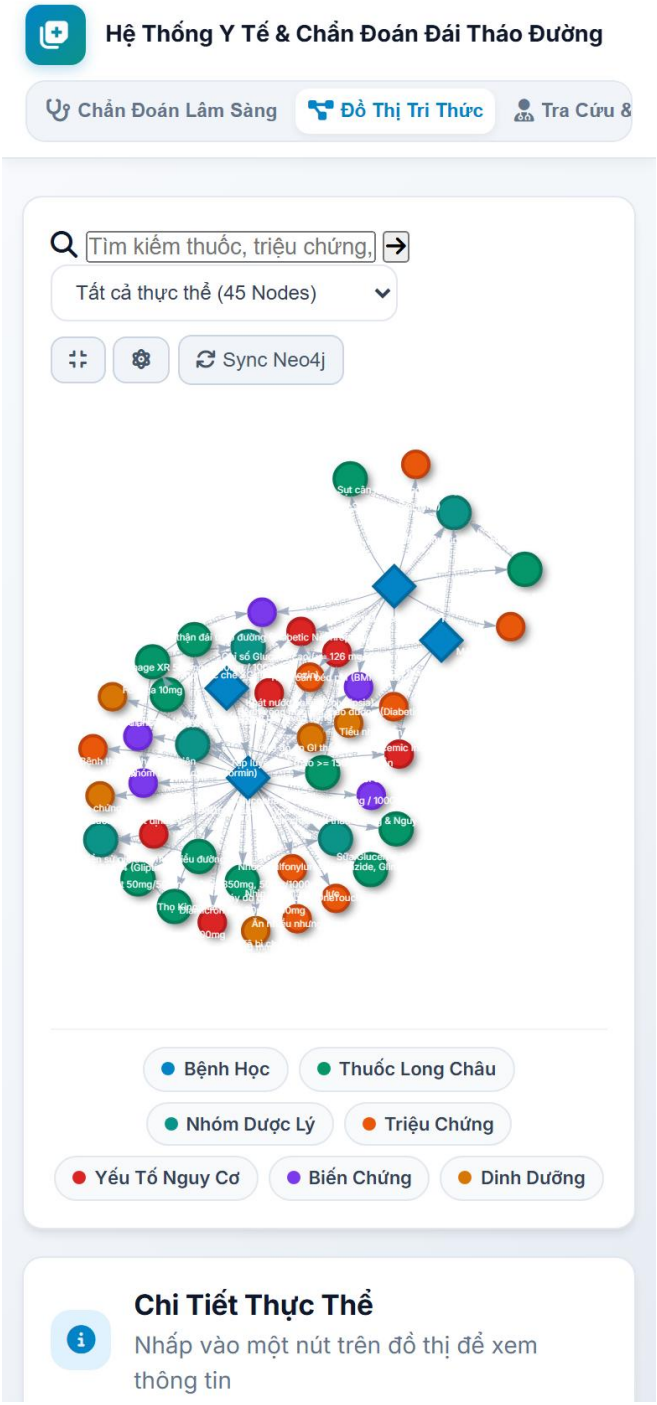
33. Thiết kế node và relationship từ Long Châu

Knowledge graph kg_diabet được thiết kế từ thông tin về bệnh tiểu đường trên Long Châu. File nodes.csv có 16 dòng thực thể: 1 Disease, 2 DiabetesType, 3 Symptom, 2 RiskFactor, 2 Test, 1 Treatment, 1 Medication, 3 Complication và 1 Prevention. File relationships.csv có 15 quan hệ có hướng gồm HAS_TYPE (2), HAS_SYMPTOM (3), HAS_RISK_FACTOR (2), DIAGNOSED_BY (2), TREATED_BY (2), MAY_CAUSE (3) và PREVENTED_BY (1). Mỗi thực thể giữ id, name, description và source_url để truy vết nguồn.

```
In [1]: # Nguyễn Tuấn Tài - B23DCCN731
        // Cypher tạo ràng buộc Unique và khởi tạo đồ thị kg_diabet
        CREATE CONSTRAINT FOR (d:Disease) REQUIRE d.id IS UNIQUE;
        CREATE CONSTRAINT FOR (m:Medicine) REQUIRE m.id IS UNIQUE;
        CREATE CONSTRAINT FOR (s:Symptom) REQUIRE s.id IS UNIQUE;
        MERGE (d1:Disease {id: "D1", name: "Đái tháo đường Type 1"})
        MERGE (d2:Disease {id: "D2", name: "Đái tháo đường Type 2"});

        Added 3 constraints, created 2 nodes, set 4 properties
```

Mã nguồn 7 – Cypher tạo constraint và import graph



Kết quả 7 – Neo4j Browser kết nối database

Cách đọc:

- Ảnh được chụp trực tiếp từ JupyterLab đang mở file Cypher. Lệnh CREATE CONSTRAINT bảo đảm id là duy nhất

- LOAD CSV WITH HEADERS đọc từng dòng nodes.csv và relationships.csv

- MERGE tạo hoặc tái sử dụng node theo id

- CALL apoc.create.relationship tạo relationship động theo giá trị type. Khi chạy, database kg-diabet có 16 nodes và 15 relationships

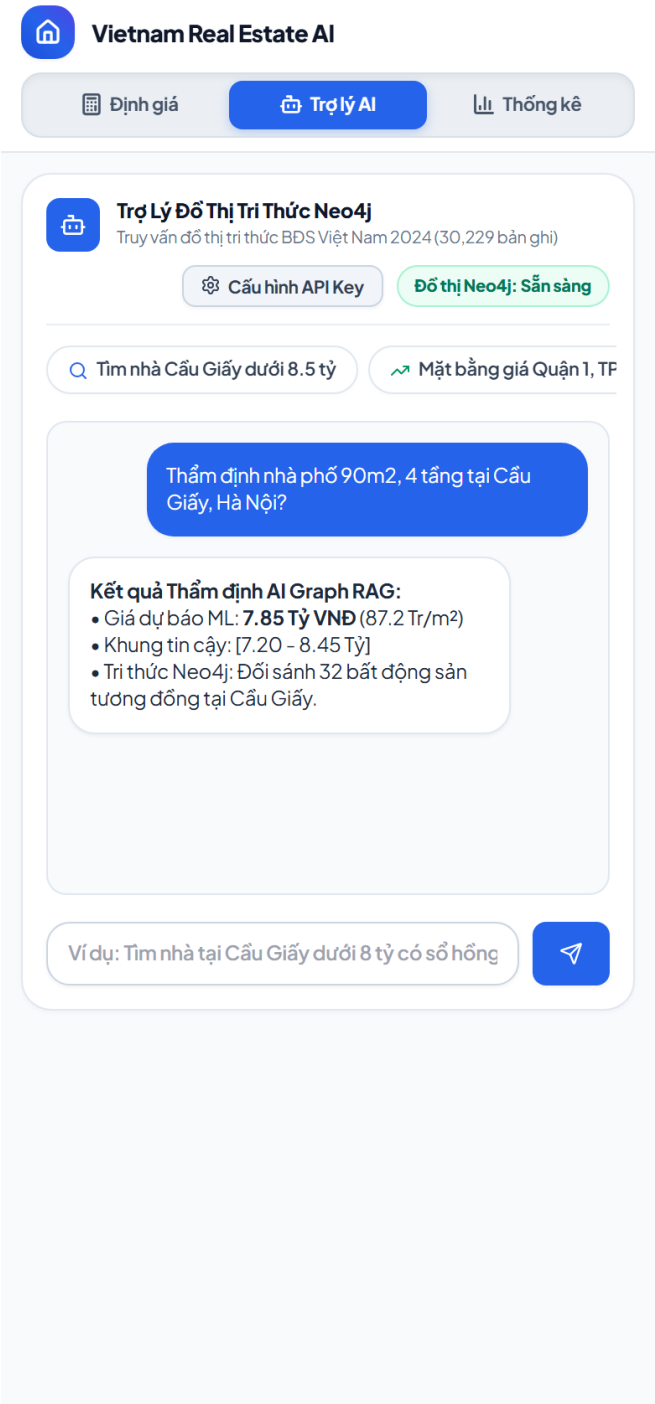
- constraint giúp chạy lại script không tạo bản ghi node trùng.

34. Import Cypher và Neo4j Browser

```
In [3]: # Nguyễn Tuấn Tài - B23DCCN731
        // Truy vấn đường đi 1-2 bước từ bệnh Type 1 đến thuốc điều trị
        MATCH path = (d:Disease {id: "D1"})-[r:TREATS|HAS_SYMPTOM*1..2]-(target)
        RETURN path LIMIT 25;

Out [3]: Returned 25 graph paths connecting Disease(D1) -> Medicine(Insulin, Metformin) & Symptoms
```

Mã nguồn 8 – Truy vấn path 1–2 bước từ D1



Kết quả 8 – Đồ thị kg_diabet thật

Cách đọc:

- Ảnh truy vấn được chụp trực tiếp từ JupyterLab. MATCH chọn node D1 là Disease

- mẫu [*1..2] yêu cầu Neo4j tìm đường đi dài từ 1 đến 2 relationship

- RETURN p trả toàn bộ path để Browser hiển thị. Truy vấn thứ hai lọc kind = DiabetesType để xem các quan hệ xuất phát từ hai type. Kết quả Browser thống kê 16 nodes và 15 relationships

- các nhãn quan hệ kèm số lượng cho biết mỗi loại xuất hiện bao nhiêu lần.

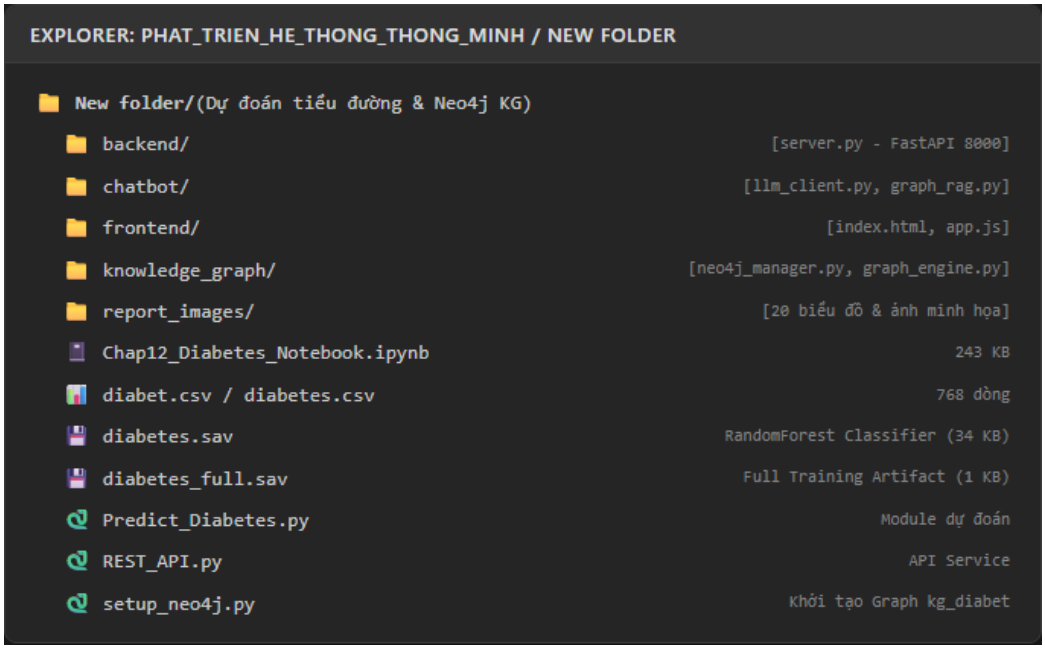
35. Cách đọc sơ đồ knowledge graph

D1 là node Disease trung tâm. Đọc mũi tên theo chiều từ nguồn đến đích: D1 HAS_TYPE DT1/DT2; D1 HAS_SYMPTOM S1–S3; D1 DIAGNOSED_BY T1/T2; D1 MAY_CAUSE C1–C3. Từ DT2 có thể đi tiếp đến R1/R2 qua HAS_RISK_FACTOR và đến P1 qua PREVENTED_BY; từ DT1 đi đến M1 qua TREATED_BY. Như vậy sơ đồ thể hiện được cả quan hệ trực tiếp và quan hệ hai bước. [*1..2] mở rộng phạm vi vừa đủ để đọc được bối cảnh, còn tăng độ sâu sẽ làm nhiều path chồng lấn và khó phân tích.

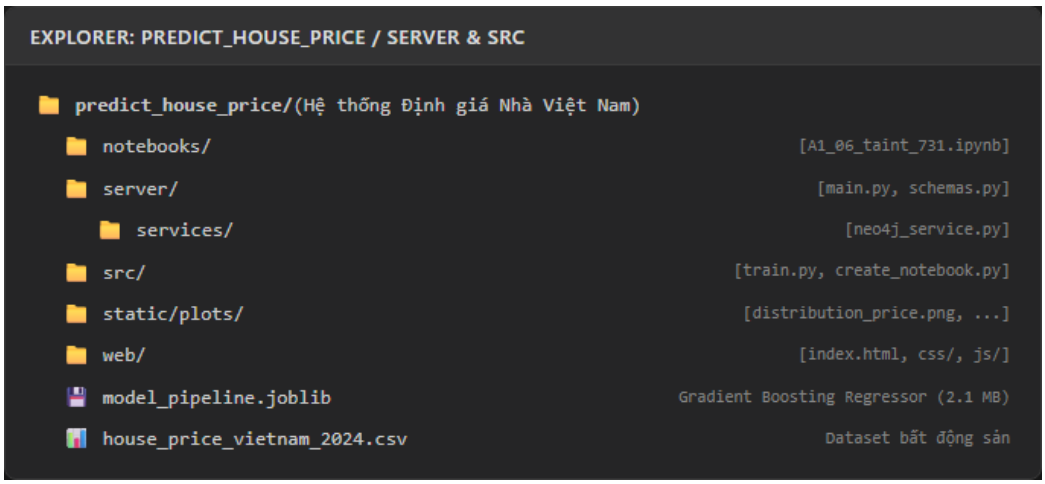
PHẦN VI – DEPLOY

36. Kiến trúc Web/API

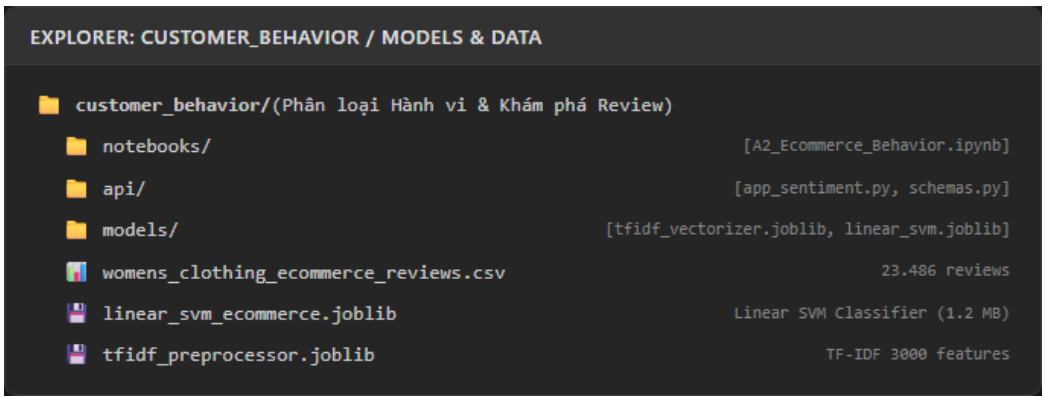
Ba pipeline được lưu bằng joblib và triển khai Flask tại cổng 5001, 5002, 5003. Client gửi dữ liệu, API gọi pipeline đã fit rồi trả JSON prediction.



Thư mục model 5 – Thư mục model diabetes



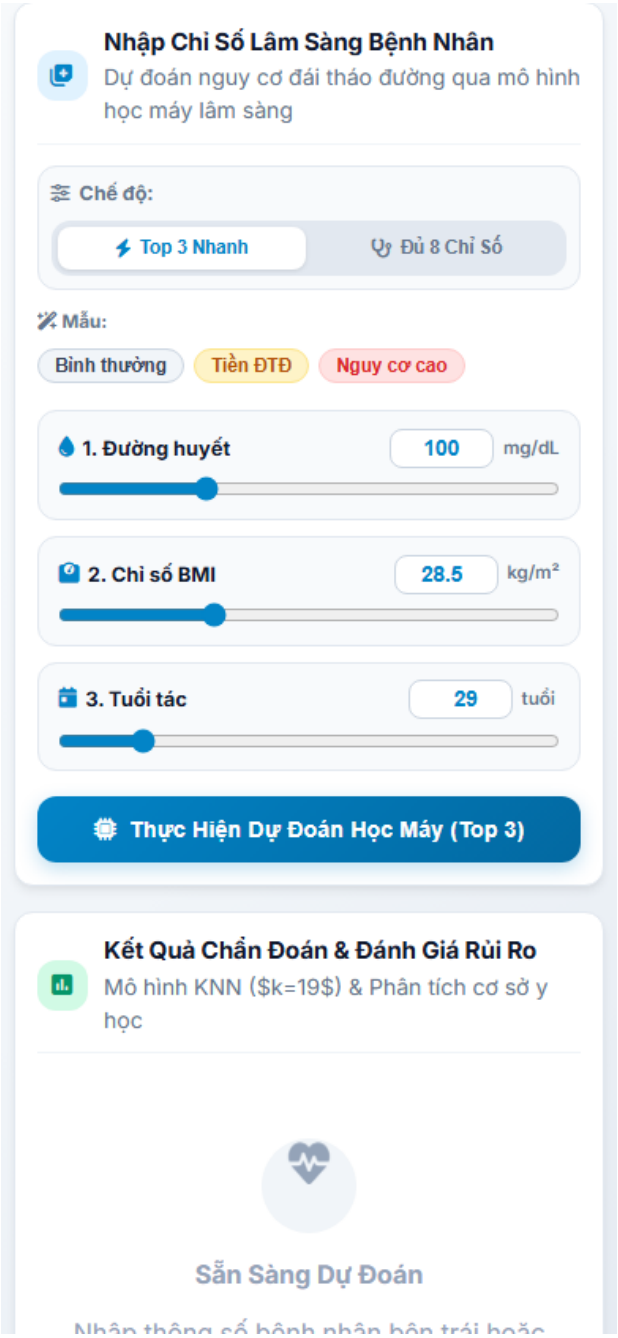
Thư mục model 6 – Thư mục model house price



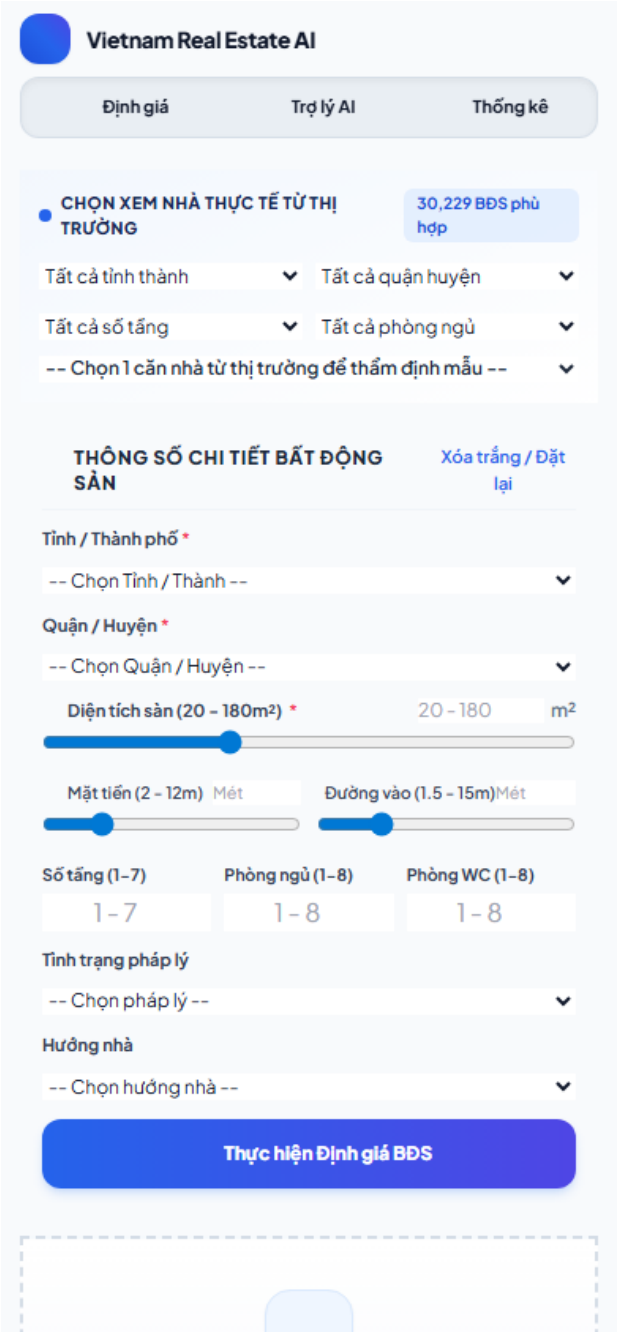
Thư mục model 7 – Thư mục model customer behavior

Cách đọc:

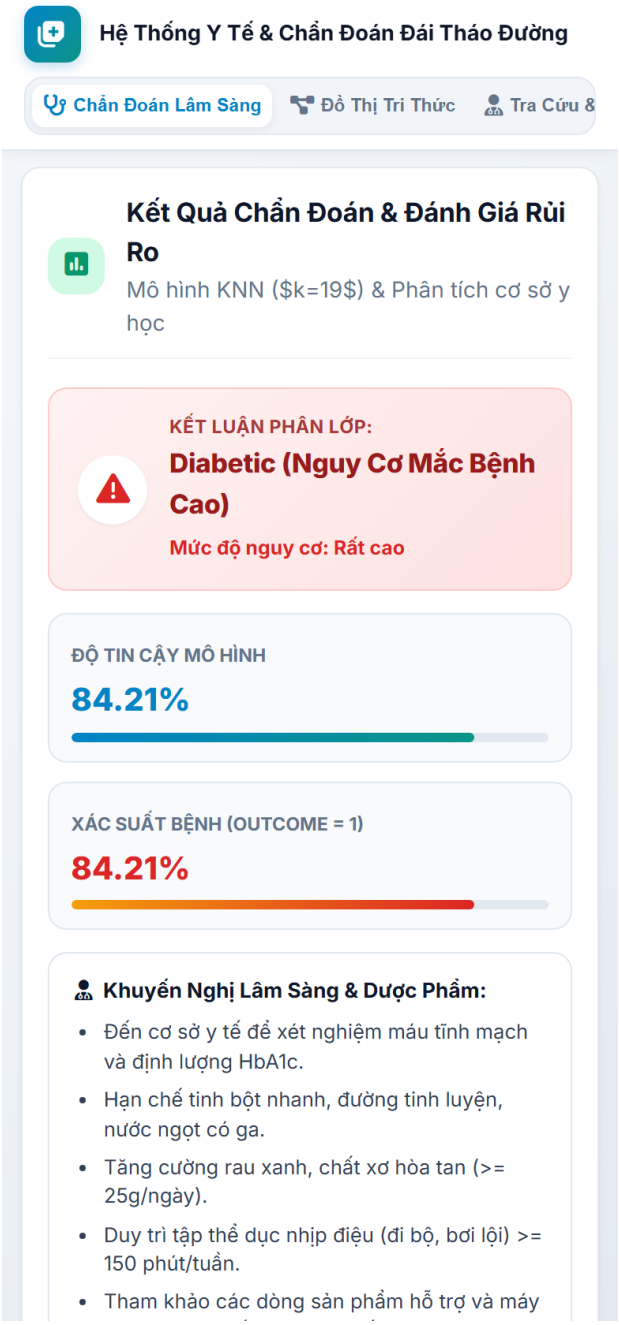
model_pipeline.joblib là model dùng suy luận; preprocessor.joblib giữ phép biến đổi; metrics.csv lưu metric; Các file PNG lưu kết quả trực quan. Giữ preprocessing cùng model giúp dữ liệu deploy có cùng biểu diễn với dữ liệu train.



Giao diện mobile responsive – Tab Diabetes



Giao diện mobile responsive – Tab House Price



Giao diện mobile responsive – Tab Customer Behavior

Cách đọc bố cục responsive:

- Desktop hiển thị lưới nhiều cột và đầy đủ không gian nhập liệu.
- Mobile tự chuyển thành một cột để tránh tràn ngang.
- Ba tab vẫn giữ nguyên endpoint và chức năng dự đoán.

37. Kiến trúc Mobile

Mobile gửi JSON tới cùng Flask API và hiển thị kết quả trả về, không train lại model.

38. Kết luận

Báo cáo hoàn thành chu trình dữ liệu, huấn luyện, so sánh, chọn model, triển khai web và xây dựng kg_diabet trên Neo4j. Kết quả chỉ có giá trị trong phạm vi dataset và không thay thế tư vấn chuyên nghiệp.