HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN 1



BÁO CÁO ASSIGNMENT 03

HỌC PHẦN PHÁT TRIỂN CÁC HỆ THỐNG THÔNG MINH

Lớp	D23CQCN-06B
Họ và tên:	Nguyễn Việt Thái
Mã sinh viên:	B23DCCN748
Giảng viên hướng dẫn:	PGS.TS Trần Đình Quế
Học kỳ:	Học kỳ 1 năm học 2026 – 2027

Hà Nội, 2026

TÓM TẮT BÁO CÁO

Báo cáo này xây dựng và đánh giá ba hệ thống thông minh trên đúng ba tệp CSV được cung cấp. Bài toán thứ nhất là phân loại đa lớp trạng thái tiểu đường từ 1.000 hồ sơ xét nghiệm; bài toán thứ hai là hồi quy giá nhà trên 545 bất động sản; bài toán thứ ba được thiết kế lại theo yêu cầu thành khám phá User Interest từ 541.909 dòng giao dịch thương mại điện tử. Mỗi bài toán sử dụng ba mô hình Machine Learning cơ bản phù hợp với bản chất dữ liệu và một mô hình Deep Learning 5 lớp được lập trình bằng NumPy, không dùng PyTorch/TensorFlow cho phần mạng nơ-ron.

Điểm khác biệt quan trọng của bản báo cáo mở rộng là phần E-commerce không tự tạo nhãn trung thành. Thay vào đó, trường Description được biến đổi bằng TF-IDF, sau đó NMF trích xuất 8 chủ đề sản phẩm. Hồ sơ sở thích của mỗi CustomerID được tính theo tỷ trọng doanh thu trên 8 chủ đề và phân cụm thành các nhóm sở thích. Cách xây dựng này bám sát dữ liệu thực tế và tránh suy diễn một biến mục tiêu không tồn tại trong file.

Đối với Deep Learning, báo cáo trình bày chi tiết kiến trúc 5 lớp, He initialization, ReLU, Softmax/Linear/Tanh, hàm mất mát Cross-Entropy hoặc MSE, lan truyền tiến, lan truyền ngược theo Chain Rule và cập nhật Adam. Các số liệu hiệu năng, biểu đồ và bảng kết quả trong báo cáo được tính lại trực tiếp từ dữ liệu thực nghiệm với random seed 42.

MỤC LỤC NỘI DUNG

CHƯƠNG 1: Tổng quan và thiết kế thực nghiệm

CHƯƠNG 2: Cơ sở lý thuyết Machine Learning và Deep Learning

CHƯƠNG 3: Deep Learning 5 lớp từ đầu bằng NumPy - giải thích chi tiết các hàm

CHƯƠNG 4: Ứng dụng 1 - Phân loại trạng thái tiểu đường

CHƯƠNG 5: Ứng dụng 2 - Dự đoán giá nhà

CHƯƠNG 6: Ứng dụng 3 - E-commerce User Interest Discovery

CHƯƠNG 7: So sánh và đánh giá đa mô hình

CHƯƠNG 8: Thiết kế triển khai hệ thống

CHƯƠNG 9: Tính tái lập và tổ chức mã nguồn

CHƯƠNG 10: Kết luận, hạn chế và hướng phát triển

PHỤ LỤC A: Data Dictionary

PHỤ LỤC B: Cấu hình mô hình và mã hàm cốt lõi

CHƯƠNG 1: TỔNG QUAN VÀ THIẾT KẾ THỰC NGHIỆM

1.1 Mục tiêu của Assignment 03

Mục tiêu của Assignment 03 không chỉ là gọi một thư viện để nhận kết quả dự đoán, mà là thiết kế trọn vẹn một quy trình hệ thống thông minh: hiểu cấu trúc dữ liệu, kiểm tra chất lượng, định nghĩa đúng bài toán, xây dựng baseline Machine Learning, tự hiện thực mô hình Deep Learning, đánh giá định lượng và mô tả cách đưa mô hình vào một dịch vụ phần mềm. Báo cáo giữ tinh thần của báo cáo tham chiếu nhưng mở rộng chiều sâu phân tích và thay đổi kiến trúc Deep Learning từ 3 lớp lên 5 lớp theo yêu cầu.

Sử dụng đúng 3 dataset người dùng cung cấp; không thay bằng dataset khác.

Mỗi bài toán có 3 mô hình cơ bản tự chọn, phù hợp với classification, regression hoặc clustering.

Mỗi bài toán có một hướng Deep Learning 5 lớp được lập trình trực tiếp bằng NumPy.

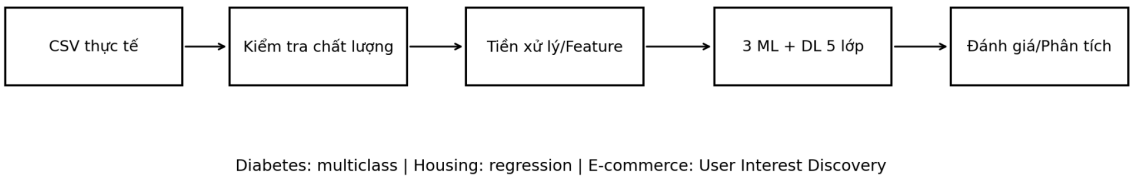
Tất cả bước chuẩn hóa supervised learning được fit trên tập Train để tránh data leakage.

E-commerce được đổi thành User Interest Discovery, khai thác Description thay vì tự tạo nhãn loyalty.

Các kết quả báo cáo là kết quả chạy thật với random_state/seed = 42.

1.2 Ba dataset và ba bài toán

Dataset	Kích thước	Task	Target/Output	3 mô hình cơ bản	Deep Learning
Diabetes	1.000 x 14	Multiclass classification	CLASS: N/P/Y	Logistic, Decision Tree, Random Forest	5-layer MLP + Softmax
Housing	545 x 13	Continuous regression	price	Linear, Decision Tree, Random Forest	5-layer MLP + Linear
E-commerce	541.909 x 8 raw	User Interest clustering	Không có nhãn sẵn	K-Means, Agglomerative, GMM	5-layer Autoencoder + K-Means



Hình 1.1. Quy trình thực nghiệm end-to-end trên ba dataset.

1.3 Nguyên tắc đánh giá

Ba bài toán có bản chất khác nhau nên không thể dùng một thước đo duy nhất. Với Diabetes, báo cáo sử dụng Accuracy, Macro Precision, Macro Recall, Macro F1 và ROC-AUC multiclass OVR; Macro F1 được nhấn mạnh vì CLASS mất cân bằng mạnh. Với Housing, các độ đo là MAE, RMSE và R^2. Với User Interest không có nhãn đúng/sai, báo cáo dùng Silhouette, Davies-Bouldin (DB) và Calinski-Harabasz (CH), đồng thời đánh giá khả năng diễn giải các cụm qua từ khóa chủ đề và sản phẩm mua nhiều.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT MACHINE LEARNING VÀ DEEP LEARNING

2.1 Machine Learning truyền thống và Deep Learning

Machine Learning truyền thống thường học một ánh xạ trực tiếp y_hat = f(X), trong đó phần biểu diễn đặc trưng chủ yếu do người thiết kế pipeline quyết định. Deep Learning mở rộng thành một chuỗi phép biến đổi có tham số: X -> f1(X) -> f2(f1(X)) -> f3(...) -> output. Các lớp ẩn tạo ra representation trung gian, cho phép mô hình học quan hệ phi tuyến phức tạp. Trong báo cáo này, mạng 5 lớp được hiểu theo cách đếm: Input là lớp 1, ba hidden layers là lớp 2-4 và Output là lớp 5.

2.2 Vì sao cần hàm kích hoạt phi tuyến?

Nếu mọi lớp đều tuyến tính, tích của nhiều phép biến đổi affine vẫn tương đương một phép biến đổi affine duy nhất. Khi đó xếp chồng nhiều lớp không làm tăng năng lực biểu diễn. ReLU(z)=max(0,z) phá tính tuyến tính, giữ gradient bằng 1 ở miền dương và có chi phí tính toán rất thấp. Trong ba mạng supervised, ReLU được dùng ở ba hidden layers.

2.3 Output activation phải phụ thuộc loại bài toán

Diabetes multiclass: Softmax chuyển vector logits thành phân phối xác suất trên N, P, Y; tổng xác suất bằng 1.

Housing regression: Output tuyến tính, không chặn miền giá trị vì price là biến liên tục.

User Interest Autoencoder: bottleneck dùng tanh để nén biểu diễn vào miền hữu hạn; output tuyến tính để tái tạo vector topic share.

2.4 Loss function là tín hiệu học

Với phân loại đa lớp, Cross-Entropy được tính L = -sum_i w_i sum_c y_ic log(p_ic) / sum_i w_i. Trọng số lớp w_i giúp hạn chế việc lớp Y chiếm 84,4% số mẫu làm mô hình bỏ qua N và P. Với hồi quy và Autoencoder, MSE đo bình phương khoảng cách giữa giá trị dự đoán và giá trị thật/tái tạo. Báo cáo cộng thêm L2 regularization lên các ma trận W để hạn chế trọng số tăng quá lớn.

2.5 Gradient, Backpropagation và Chain Rule

Backpropagation tính đạo hàm của loss theo từng W và b theo chiều ngược từ output về input. Ví dụ ở tầng cuối của classifier Softmax + Cross-Entropy, gradient logits có dạng gọn dz4 = (p - Y) * sample_weight / tổng trọng số. Gradient này được nhân với chuyển vị activation tầng trước để thu dW4, sau đó truyền qua W4^T và đạo hàm ReLU để đi tiếp xuống tầng 3, 2 và 1.

2.6 Adam optimizer

Thay vì cập nhật Gradient Descent thuần W <- W - lr*dW, bản mở rộng sử dụng Adam được tự cài đặt bằng NumPy. Adam duy trì trung bình động bậc một m_t của gradient và bậc hai v_t của bình phương gradient; sau hiệu chỉnh bias, cập nhật có dạng theta <- theta - lr*m_hat/(sqrt(v_hat)+epsilon). Lợi ích là tốc độ học thích nghi cho từng tham số, giúp mạng 5 lớp ổn định hơn trên ba dataset có thang đo và kích thước rất khác nhau.

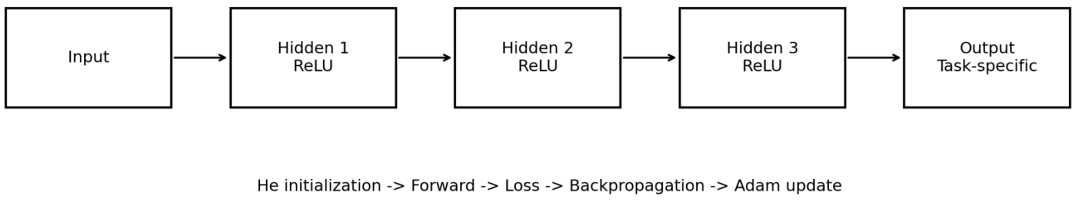
2.7 Train/Test split, Standardization và data leakage

Với hai bài toán supervised, dữ liệu được chia Train/Test 80/20 với seed 42. Diabetes dùng stratified split để bảo toàn tỷ lệ N/P/Y. StandardScaler và OneHotEncoder chỉ fit trên Train rồi transform Test. Điều này quan trọng vì nếu mean/std hoặc thống kê category của Test tham gia bước fit, mô hình đã nhận thông tin từ dữ liệu đánh giá và điểm số sẽ lạc quan hơn thực tế.

2.8 Ba nhóm mô hình cơ bản được chọn

Bài toán	Model 1	Model 2	Model 3	Lý do chọn
Diabetes	Logistic Regression	Decision Tree	Random Forest	Tuyến tính -> cây đơn -> ensemble; đối chiếu độ phức tạp tăng dần.
Housing	Linear Regression	Decision Tree Regressor	Random Forest Regressor	Baseline tuyến tính và hai mô hình cây cho quan hệ phi tuyến.
User Interest	K-Means	Agglomerative	Gaussian Mixture	Đại diện centroid, phân cấp và xác suất hỗn hợp.

CHƯƠNG 3: DEEP LEARNING 5 LỚP TỪ ĐẦU BẰNG NUMPY - GIẢI THÍCH CHI TIẾT CÁC HÀM



Hình 3.1. Kiến trúc 5 lớp khái quát dùng trong hai bài toán supervised.

3.1 Quy ước kiến trúc 5 lớp

Classifier Diabetes và Regressor Housing có kiến trúc Input(d) -> Hidden1(64) -> Hidden2(32) -> Hidden3(16) -> Output. Như vậy có 5 lớp theo cách đếm gồm lớp dữ liệu đầu vào. Có bốn cặp tham số (W1,b1) đến (W4,b4). Kích thước output là 3 cho Diabetes và 1 cho Housing. User Interest Autoencoder cũng có 5 lớp khái niệm: Input(8 topic shares) -> Hidden(16) -> Bottleneck(4) -> Hidden(16) -> Reconstruction(8).

3.2 Hàm He Initialization

```
def he_matrix(fan_in, fan_out, rng):
    return rng.standard_normal((fan_in, fan_out)) * np.sqrt(2.0 / fan_in)
```

Hàm nhận số chiều đầu vào fan_in và số neuron đầu ra fan_out. np.random.standard_normal tạo trọng số trung bình xấp xỉ 0; hệ số sqrt(2/fan_in) giữ phương sai activation phù hợp khi đi qua ReLU. Nếu khởi tạo tất cả trọng số bằng 0, các neuron trong cùng một lớp học giống hệt nhau và mạng mất khả năng phá vỡ đối xứng.

3.3 Hàm ReLU và đạo hàm

```
def relu(z):
    return np.maximum(0.0, z)

def relu_grad(z):
    return (z > 0).astype(float)
```

relu giữ nguyên phần dương và đưa phần âm về 0. relu_grad tạo mask đạo hàm: 1 khi z > 0 và 0 khi z <= 0. Trong Backpropagation, gradient từ lớp sau được nhân element-wise với mask này, nhờ đó chỉ những neuron đang hoạt động ở miền dương mới truyền gradient về trước.

3.4 Hàm Softmax ổn định số

```
def softmax(z):
    z = z - np.max(z, axis=1, keepdims=True)
    e = np.exp(np.clip(z, -50, 50))
    return e / np.sum(e, axis=1, keepdims=True)
```

Trừ max(z) trên mỗi mẫu không thay đổi xác suất Softmax nhưng tránh exp của số rất lớn gây overflow. np.clip là lớp bảo vệ số học bổ sung. Kết quả mỗi hàng là vector xác suất ba lớp N/P/Y, có giá trị trong (0,1) và tổng bằng 1.

3.5 Hàm forward_5layer

```
z1 = X @ W1 + b1; a1 = relu(z1)
z2 = a1 @ W2 + b2; a2 = relu(z2)
z3 = a2 @ W3 + b3; a3 = relu(z3)
z4 = a3 @ W4 + b4
```

Forward pass thực hiện lần lượt phép biến đổi affine và ReLU ở ba hidden layers. Các biến z1, a1, z2, a2, z3, a3 được lưu vào cache vì Backpropagation cần chính các giá trị này để áp dụng Chain Rule. Ở classifier, z4 đi qua Softmax; ở regressor, z4 chính là y_hat vì output tuyến tính.

3.6 Weighted Cross-Entropy cho Diabetes

```
loss = -np.sum(sample_weight * Y * np.log(np.clip(prob, 1e-9, 1.0))) /
sample_weight.sum()
dz4 = (prob - Y) * sample_weight / sample_weight.sum()
```

CLASS sau làm sạch có 844 mẫu Y, 103 mẫu N và 53 mẫu P. Nếu không có class weight, một mô hình ưu tiên Y vẫn có thể đạt Accuracy cao. Weighted Cross-Entropy tăng tác động của lớp hiếm trong gradient. Công thức dz4 = prob - Y là dạng rút gọn của đạo hàm Softmax kết hợp Cross-Entropy; sample_weight chỉ điều chỉnh mức đóng góp của từng mẫu.

3.7 MSE cho Housing và Autoencoder

```
diff = y_hat - y
loss = 0.5 * np.mean(diff ** 2)
d_y_hat = diff / n
```

Hệ số 0,5 không thay đổi vị trí cực tiểu nhưng làm đạo hàm của bình phương gọn thành diff thay vì 2*diff. Housing chuẩn hóa y_train trước khi học để gradient có thang ổn định; sau dự đoán, inverse_transform đưa kết quả trở lại đơn vị price gốc. Autoencoder cũng dùng MSE nhưng y chính là X_interest, tức nhiệm vụ học cách tái tạo hồ sơ sở thích ban đầu.

3.8 Backpropagation qua 4 ma trận trọng số

```
dW4 = a3.T @ dz4
dz3 = (dz4 @ W4.T) * relu_grad(z3)
dW3 = a2.T @ dz3
dz2 = (dz3 @ W3.T) * relu_grad(z2)
dW2 = a1.T @ dz2
dz1 = (dz2 @ W2.T) * relu_grad(z1)
dW1 = X.T @ dz1
```

Mỗi dòng là một mắt xích Chain Rule. Chuyển vị activation của lớp trước nhân gradient của lớp hiện tại tạo gradient theo W. Sau đó gradient được đưa ngược qua W^T và nhân đạo hàm activation. Bias gradient là tổng gradient theo trục sample vì một bias được broadcast cho mọi mẫu trong batch.

3.9 Hàm Adam update

```
m = beta1*m + (1-beta1)*g
v = beta2*v + (1-beta2)*(g*g)
m_hat = m / (1-beta1**t)
v_hat = v / (1-beta2**t)
theta -= lr * m_hat / (np.sqrt(v_hat) + eps)
```

m theo dõi hướng gradient gần đây, còn v theo dõi cường độ bình phương gradient. Hai đại lượng được hiệu chỉnh bias ở những bước đầu vì m và v khởi tạo bằng 0. epsilon tránh chia cho 0. Trong thực nghiệm, Diabetes dùng lr=0,001 và 400 epochs; Housing dùng lr=0,0005 và 200 epochs để hạn chế overfitting; Autoencoder dùng lr=0,002 và 1.800 epochs để tối ưu reconstruction.

3.10 Autoencoder 5 lớp và bottleneck

```
Input(8) -> ReLU(16) -> tanh Bottleneck(4) -> ReLU(16) -> Linear(8)
```

Autoencoder không dự đoán nhãn. Encoder nén 8 tỷ trọng chủ đề sở thích xuống vector 4 chiều; decoder cố gắng tái tạo lại 8 tỷ trọng ban đầu. Nếu reconstruction loss giảm, bottleneck đã lưu lại phần thông tin quan trọng của user interest. K-Means sau đó chạy trên bottleneck để kiểm tra liệu representation học được có tạo cụm hợp lý hay không.

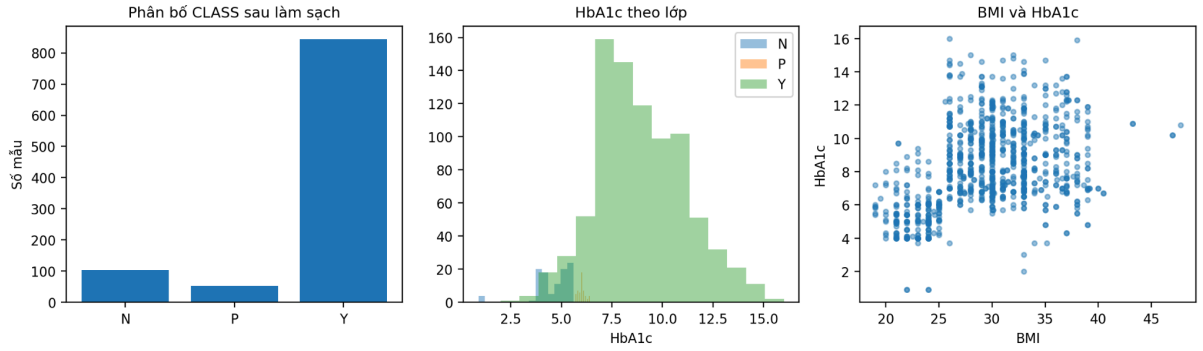
CHƯƠNG 4: ỨNG DỤNG 1 - PHÂN LOẠI TRẠNG THÁI TIỂU ĐƯỜNG

4.1 Mô tả dataset thực tế

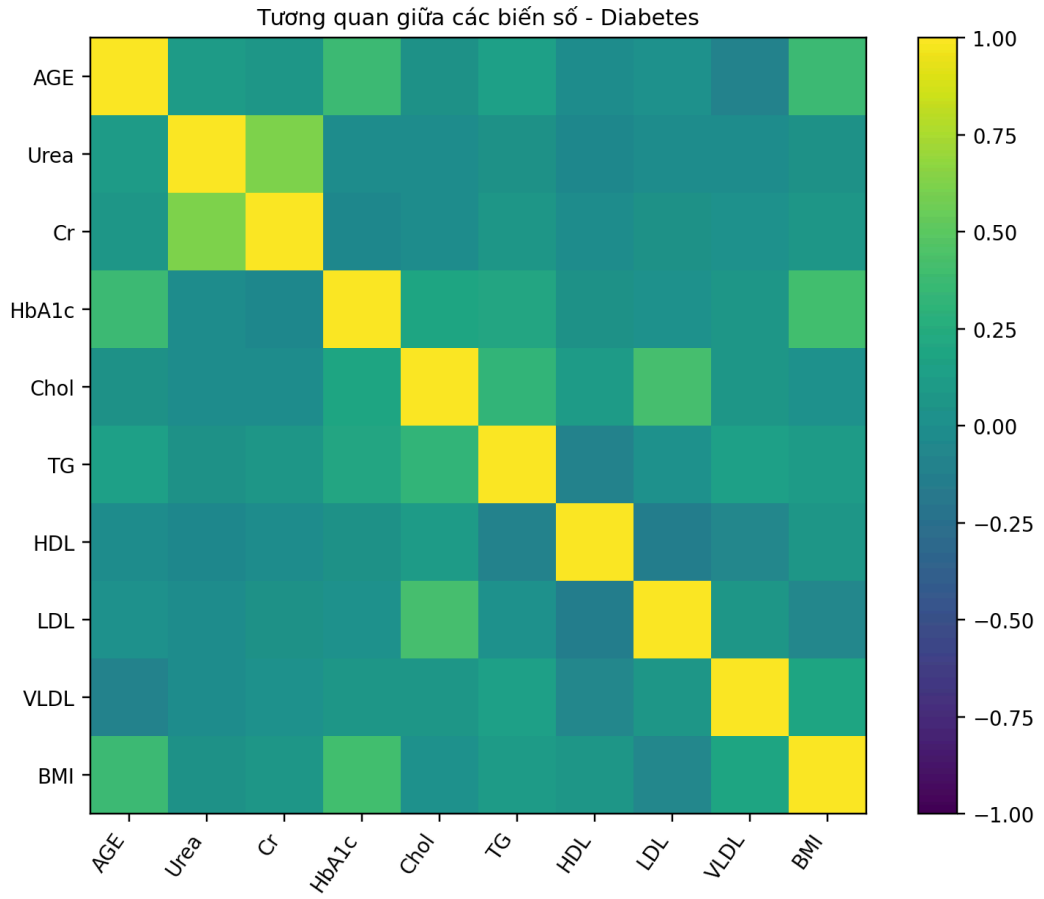
Tệp Dataset of Diabetes .csv có 1,000 bản ghi và 14 cột. Hai trường ID và No_Pation mang tính định danh, vì vậy bị loại khỏi vector đầu vào để tránh mô hình học quan hệ giả từ mã số. Sau khi loại định danh và target, hệ thống sử dụng 11 đặc trưng: Gender, AGE, Urea, Cr, HbA1c, Chol, TG, HDL, LDL, VLDL và BMI. Không có giá trị thiếu trong file.

Dữ liệu thô có CLASS xuất hiện thành 5 token do khoảng trắng cuối chuỗi (ví dụ N và "N ", Y và "Y "). Gender cũng có một giá trị "f" viết thường. Pipeline chuẩn hóa bằng strip() và upper(), sau đó CLASS còn đúng ba lớp: N=103, P=53, Y=844. Đây là bước làm sạch bắt buộc trước khi train/test split.

Biến	Mean	Std	Min	Median	Max
AGE	53.53	8.80	20.00	55.00	79.00
Urea	5.12	2.94	0.50	4.60	38.90
Cr	68.94	59.98	6.00	60.00	800.00
HbA1c	8.28	2.53	0.90	8.00	16.00
Chol	4.86	1.30	0.00	4.80	10.30
TG	2.35	1.40	0.30	2.00	13.80
HDL	1.20	0.66	0.20	1.10	9.90
LDL	2.61	1.12	0.30	2.50	9.90
VLDL	1.85	3.66	0.10	0.90	35.00
BMI	29.58	4.96	19.00	30.00	47.75



Hình 4.1. EDA: phân bố lớp, HbA1c và quan hệ BMI-HbA1c.



Hình 4.2. Ma trận tương quan các biến số của Diabetes.

4.2 Nhận xét EDA

CLASS mất cân bằng rất mạnh: Y chiếm 84.40%, N chiếm 10.30% và P chỉ chiếm 5.30%. Vì vậy Accuracy không đủ để kết luận. Macro F1 tính F1 cho từng lớp rồi lấy trung bình không trọng số, giúp lớp P vẫn có tiếng nói ngang với Y trong thước đo tổng hợp.

HbA1c có khác biệt rõ theo nhóm: median N=4.9, P=6.0, Y=8.8. BMI median lần lượt là 22.0, 24.0 và 30.0. Đây là dấu hiệu cho thấy các biến chuyển hóa có lực phân tách đáng kể trong chính dataset được cung cấp; báo cáo chỉ diễn giải mối liên hệ trong dữ liệu, không coi mô hình là chẩn đoán y khoa thực tế.

4.3 Tiền xử lý và cấu hình model

Train/Test = 80/20, stratify=CLASS, random_state=42.

10 biến số được StandardScaler fit trên Train; Gender được OneHotEncoder(drop="if_binary").

Logistic Regression: class_weight="balanced", max_iter=3000.

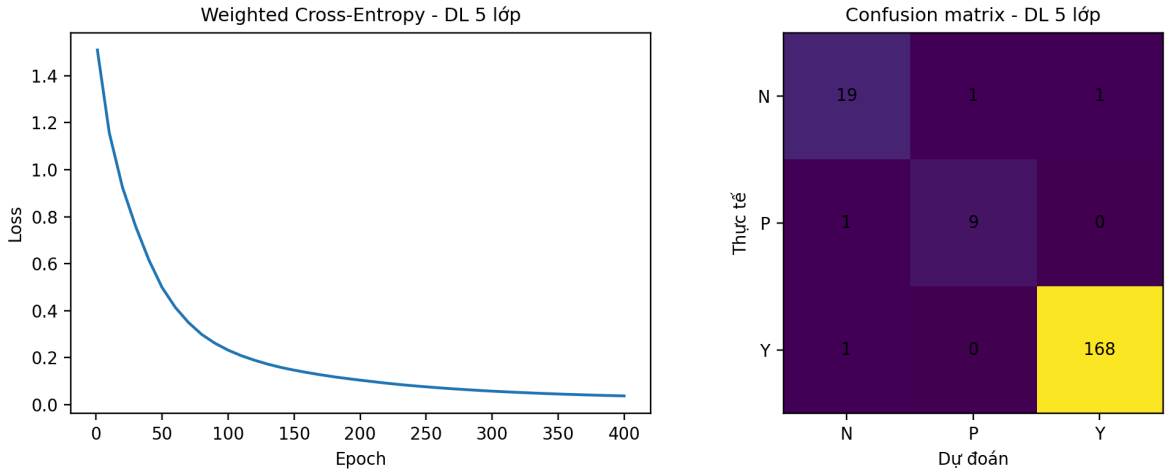
Decision Tree: max_depth=6, class_weight="balanced".

Random Forest: 500 cây, max_depth=12, class_weight="balanced_subsample".

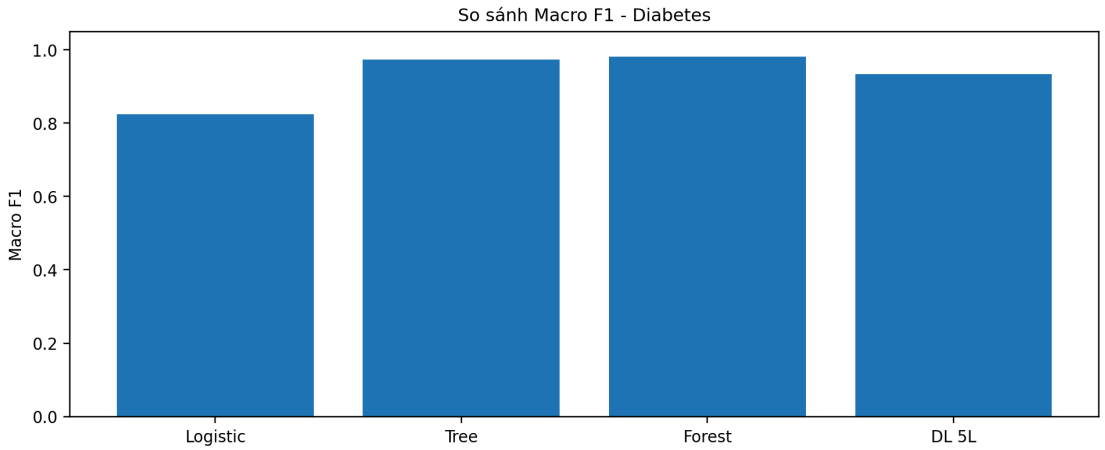
DL 5 lớp: Input(11) -> 64 ReLU -> 32 ReLU -> 16 ReLU -> 3 Softmax; weighted CE; Adam lr=0,001; 400 epochs.

4.4 Kết quả thực nghiệm

Model	Accuracy	Macro P	Macro R	Macro F1	ROC-AUC	Train time
Logistic Regression	94.00%	0.7858	0.8858	0.8240	0.9815	0.019s
Decision Tree (depth=6)	99.00%	0.9961	0.9508	0.9724	0.9646	0.006s
Random Forest (500 trees)	99.50%	0.9980	0.9667	0.9815	0.9998	1.130s
NumPy DL 5-layer	98.00%	0.9329	0.9329	0.9329	0.9917	0.421s



Hình 4.3. Loss và confusion matrix của Deep Learning 5 lớp.



Hình 4.4. Benchmark Macro F1 trên Diabetes.

Kết quả cho thấy Random Forest (500 trees) có Macro F1 cao nhất (0.9815) trên split cố định. DL 5 lớp đạt Accuracy 98.00% và Macro F1 0.9329. Việc DL không nhất thiết thắng Random Forest là kết quả hợp lý trên tabular data nhỏ: ensemble tree thường tận dụng tốt các ngưỡng phân tách theo từng biến, trong khi mạng nơ-ron có nhiều tham số hơn và nhạy với regularization.

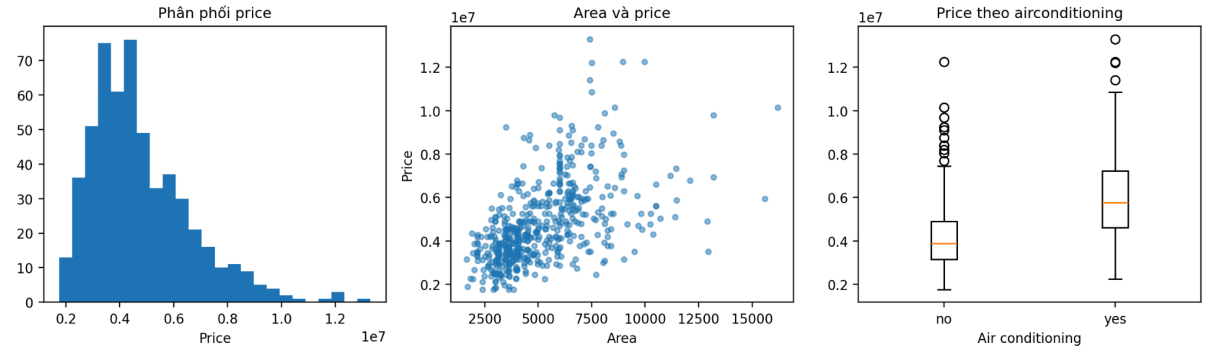
Confusion matrix của DL cho thấy phần lớn mẫu Y được nhận diện đúng, nhưng các lỗi còn lại tập trung ở các lớp ít mẫu N/P. Đây là lý do báo cáo dùng class-weighted loss và Macro F1. Nếu triển khai thực tế, cần thêm cross-validation, calibration và dữ liệu độc lập bên ngoài; điểm số từ 200 mẫu Test hiện tại chưa đủ để khẳng định hiệu quả lâm sàng.

CHƯƠNG 5: ỨNG DỤNG 2 - DỰ ĐOÁN GIÁ NHÀ

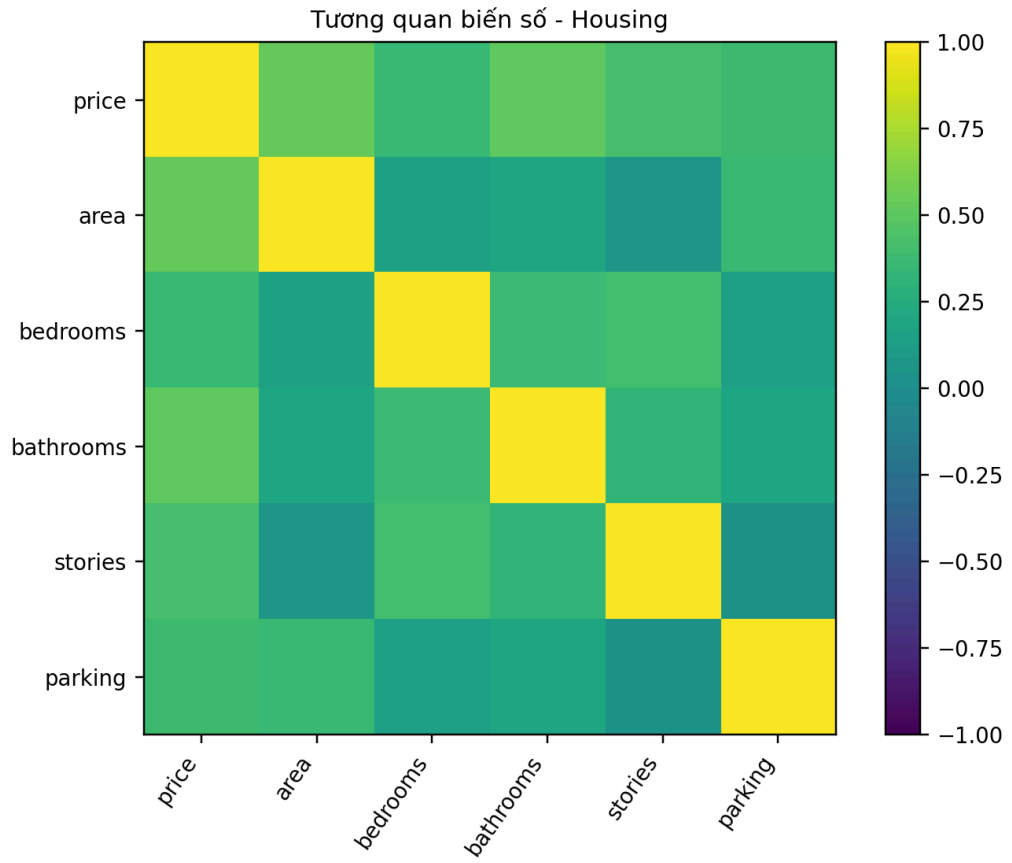
5.1 Mô tả dataset

Tệp Housing(1).csv có 545 bất động sản, 12 biến đầu vào và biến mục tiêu price. Sáu biến số gồm area, bedrooms, bathrooms, stories, parking và price; các biến còn lại là yes/no hoặc furnishingstatus. Dataset không có missing value. Price dao động từ 1,750,000 đến 13,300,000, median 4,340,000 và mean 4,766,729.

Biến số	Mean	Std	Min	Median	Max
price	4,766,729	1,870,440	1,750,000	4,340,000	13,300,000
area	5,151	2,170	1,650	4,600	16,200
bedrooms	2.97	0.74	1	3.0	6
bathrooms	1.29	0.50	1	1.0	4
stories	1.81	0.87	1	2.0	4
parking	0.69	0.86	0	0.0	3



Hình 5.1. EDA giá nhà: phân phối, area-price và điều hòa.



Hình 5.2. Tương quan giữa các biến số của Housing.

5.2 Phân tích EDA

Trong nhóm biến số, area có tương quan tuyến tính với price khoảng 0.536, bathrooms 0.518, stories 0.421, parking 0.384 và bedrooms 0.366. Những giá trị này không chứng minh quan hệ nhân quả nhưng cho thấy diện tích và tiện ích là tín hiệu có ích cho mô hình. Phân phối price lệch phải: một số căn rất đắt kéo mean lên cao hơn median.

5.3 Tiền xử lý và cấu hình model

Train/Test = 80/20, random_state=42.

Biến số StandardScaler; biến category OneHotEncoder(drop="first") fit trên Train.

Linear Regression dùng OLS làm baseline tuyến tính.

Decision Tree Regressor max_depth=6.

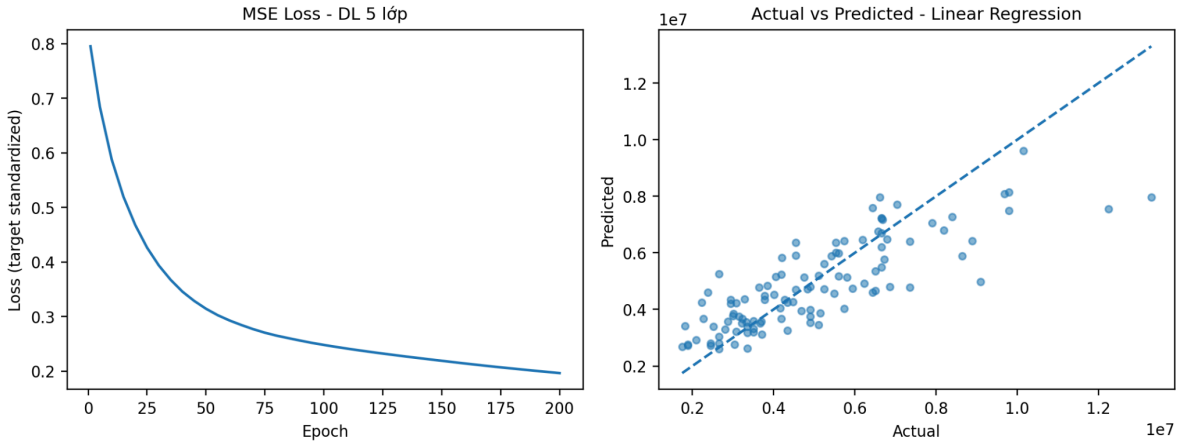
Random Forest Regressor 1.000 cây, max_features=0,8.

DL 5 lớp: Input(13) -> 64 ReLU -> 32 ReLU -> 16 ReLU -> 1 Linear. y_train được StandardScaler; MSE + L2; Adam lr=0,0005; 200 epochs.

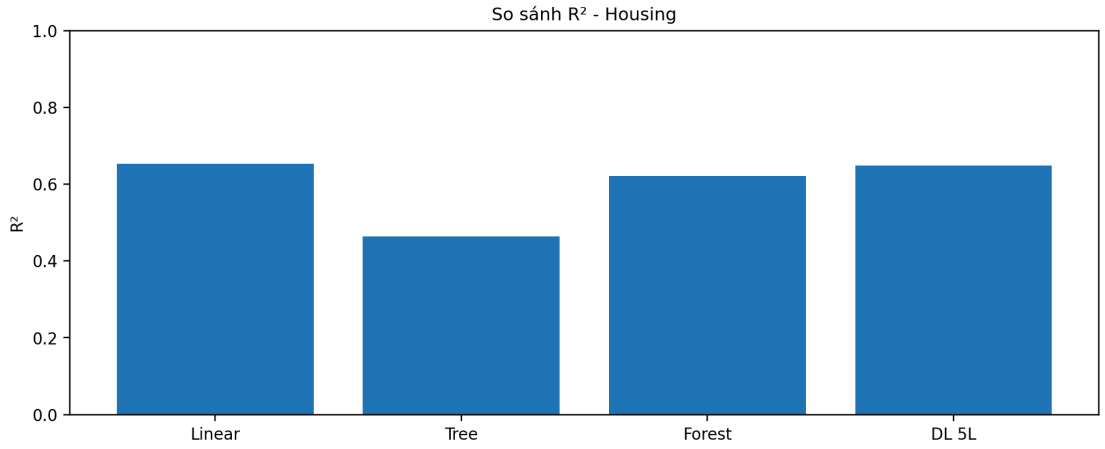
5.4 Kết quả mô hình

Model	MAE	RMSE	R^2	Train time

Linear Regression	970,043	1,324,507	0.6529	0.006s
Decision Tree (depth=6)	1,254,703	1,645,653	0.4642	0.007s
Random Forest (1000 trees)	1,010,106	1,383,398	0.6214	0.865s
NumPy DL 5-layer	985,535	1,333,376	0.6483	0.109s



Hình 5.3. Loss DL và Actual-vs-Predicted của mô hình có R² tốt nhất.



Hình 5.4. Benchmark R² trên Housing.

Linear Regression đạt R² cao nhất trên split này (0.6529), tương ứng MAE 970,043. DL 5 lớp đạt R² 0.6483, MAE 985,535. Khoảng cách giữa các mô hình không quá lớn, phản ánh dataset chỉ có 545 mẫu nên phương sai đánh giá theo một train/test split có thể đáng kể.

Điểm đáng chú ý là huấn luyện DL quá lâu làm test R² giảm dù training loss tiếp tục giảm - một dấu hiệu overfitting. Bản báo cáo dùng 200 epochs và learning rate nhỏ sau khi kiểm tra đường cong loss, thay vì mặc định hàng nghìn epochs. Đây là ví dụ cho thấy loss trên Train thấp không đồng nghĩa năng lực khái quát tốt hơn.

CHƯƠNG 6: ỨNG DỤNG 3 - E-COMMERCE USER INTEREST DISCOVERY

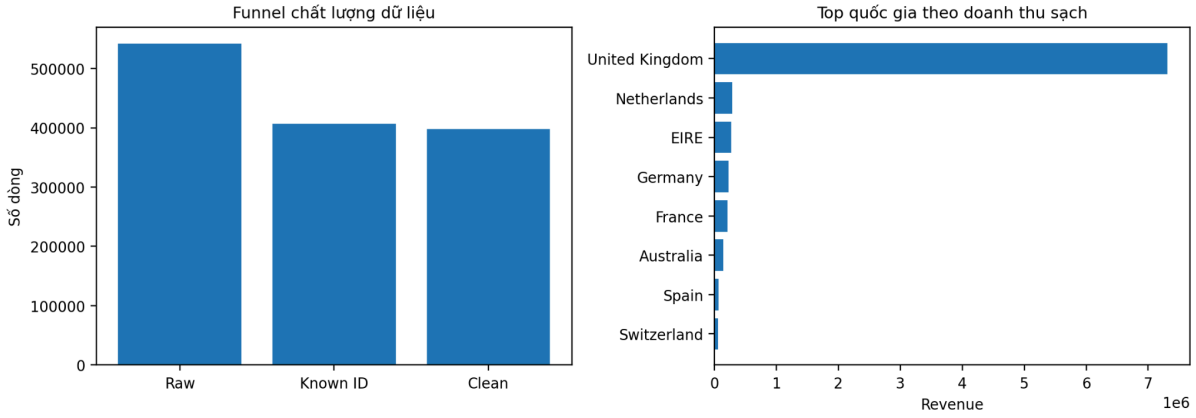
6.1 Vì sao chuyển từ loyalty sang User Interest?

Tệp data(1).csv chứa dữ liệu giao dịch: InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID và Country. File không chứa nhãn loyalty, churn hay preferred category. Vì vậy việc tự đặt Target_Loyal từ ngưỡng chi tiêu sẽ biến một quy tắc do người làm đặt ra thành "ground truth" và làm bài toán classification thiếu cơ sở. Theo yêu cầu mới, báo cáo khai thác trực tiếp sở thích người dùng từ Description và lịch sử mua hàng, tức User Interest Discovery.

6.2 Kiểm tra chất lượng và làm sạch

Dataset raw có 541,909 dòng, 25,900 invoice, 4,070 StockCode, 4,372 CustomerID đã biết và 38 quốc gia; thời gian giao dịch từ 2010-12-01 đến 2011-12-09. Có 135,080 dòng thiếu CustomerID và 1,454 dòng thiếu Description. Ngoài ra có 10,624 dòng Quantity <= 0, 2,517 dòng UnitPrice <= 0 và 9,288 dòng invoice bắt đầu bằng C.

Pipeline giữ các giao dịch có CustomerID, Description, InvoiceDate hợp lệ; Quantity > 0; UnitPrice > 0 và không phải invoice hủy. Sau làm sạch còn 397,884 dòng, 4,338 khách hàng, 18,532 invoice và doanh thu cộng dồn 8,911,407.90 theo đơn vị tiền trong file. Những dòng bị loại không bị "sửa" thành giá trị dương vì hành vi trả hàng/hủy hóa đơn có ý nghĩa khác với mua hàng dương và không phù hợp với mục tiêu xây hồ sơ sở thích mua.



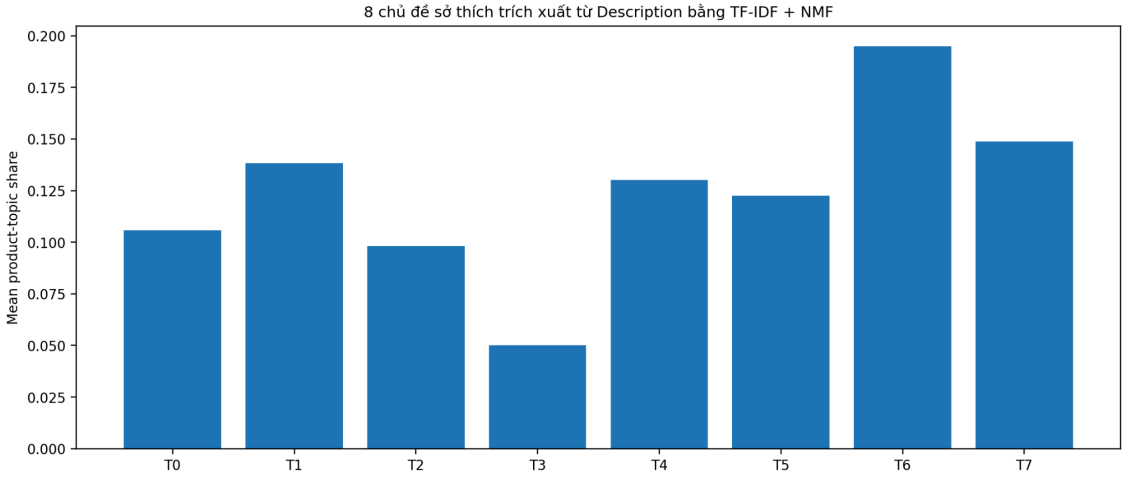
Hình 6.1. Funnel làm sạch và top quốc gia theo doanh thu.

6.3 Từ Description đến vector User Interest bằng TF-IDF + NMF

Bước 1: mỗi StockCode được gắn với Description đại diện thường gặp nhất để giảm nhiễu do mô tả biến thể. Bước 2: TF-IDF chuyển mô tả sản phẩm thành vector 600 đặc trưng từ/ngữ ghép (1-2 gram), loại stopwords tiếng Anh. Bước 3: NMF với 8 components phân rã ma trận TF-IDF thành 8 chủ đề không âm. Mỗi sản phẩm nhận một vector topic share, sau đó transaction weight = topic_share * Revenue. Cuối cùng

cộng theo CustomerID và chuẩn hóa hàng về tổng 1, tạo vector 8 chiều biểu diễn tỷ trọng chi tiêu theo chủ đề của mỗi user.

Topic	Tên diễn giải	Từ khóa nổi bật
T0	Bộ sản phẩm, giấy và phụ kiện nhà cửa	set, paper, tins, lights, wooden, candles, set 12
T1	Hoa văn hồng, hoa và đồ dệt trang trí	pink, flower, cover, cushion, cushion cover, white, polkadot
T2	Retrospot đỏ, túi và đồ bếp	red, retrospot, red retrospot, small, box, bag, bowl
T3	Biển kim loại, móc và trang trí kiểu Pháp	metal, sign, metal sign, french, blue metal, hook, door
T4	Đèn nến, trái tim và đồ treo trang trí	light, holder, heart, light holder, hanging, decoration, zinc
T5	Xanh/polkadot, vườn và gốm	blue, polkadot, blue polkadot, flower, clock, garden, design
T6	Vintage, Giáng sinh và quà tặng	vintage, christmas, bag, box, vintage christmas, card, mug
T7	Thủy tinh, trang sức và phụ kiện	glass, black, necklace, bracelet, silver, small, green



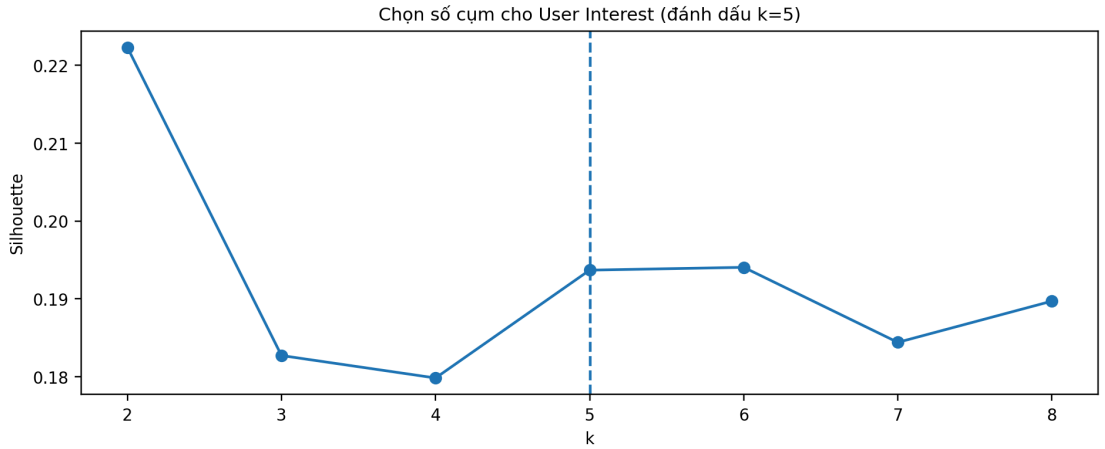
Hình 6.2. Cường độ trung bình của 8 chủ đề sản phẩm.

Tên topic trong bảng là nhãn diễn giải do người phân tích đặt dựa trực tiếp trên các từ có trọng số NMF lớn nhất; chúng không phải category chính thức có sẵn trong dataset. Vì vậy báo cáo luôn giữ danh sách top terms bên cạnh tên topic để người đọc có thể kiểm chứng cách đặt tên.

6.4 Chọn số cụm và 3 mô hình cơ bản

K-Means được chạy thử k=2 đến k=8. k=2 có Silhouette cao nhất nhưng chỉ tách dữ liệu thành hai nhóm quá rộng, khó dùng như một hệ thống khám phá interest. Báo cáo chọn k=5 như điểm cân bằng giữa chất lượng hình học và khả năng diễn giải: tại k=5 Silhouette vẫn tạo một local recovery so với k=4, trong khi có thể mô tả năm kiểu sở thích khác nhau. Đây là lựa chọn mang tính thiết kế hệ thống, được công khai thay vì tuyên bố k=5 là tối ưu tuyệt đối theo một metric duy nhất.

k	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	0.2223	1.6400	1213.2
3	0.1827	1.5858	1060.3
4	0.1798	1.5616	932.1
5	0.1937	1.4307	871.9
6	0.1940	1.4873	842.3
7	0.1844	1.4231	819.2
8	0.1897	1.3519	810.5



Hình 6.3. Silhouette theo k và lựa chọn vận hành k=5.

K-Means: tối ưu tổng bình phương khoảng cách tới centroid; nhanh và dễ mô tả centroid interest.

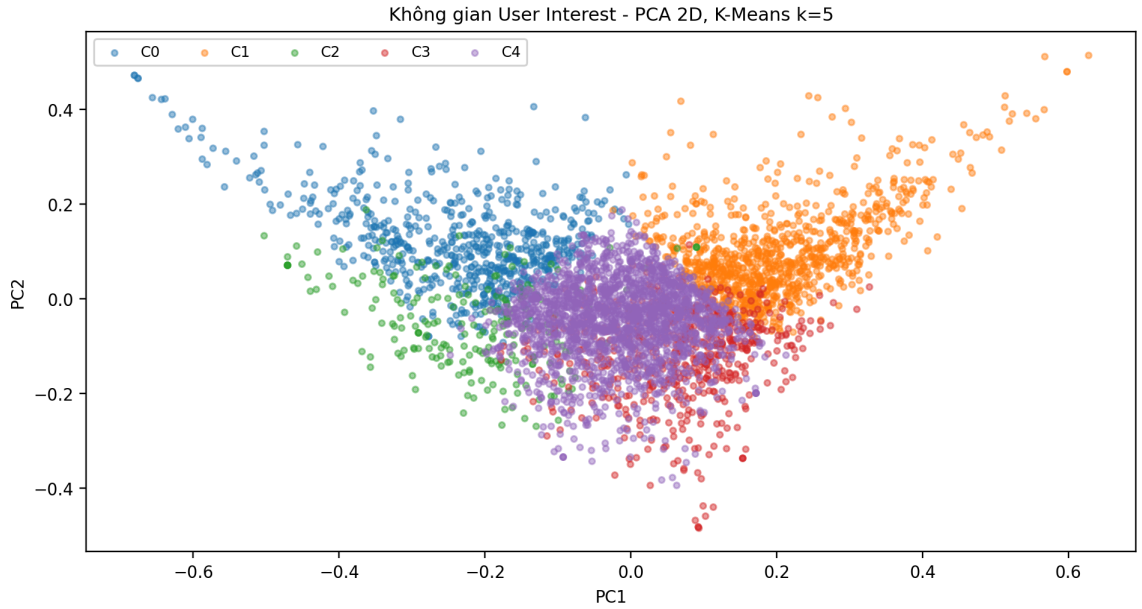
Agglomerative: bắt đầu từ từng user riêng lẻ rồi gộp cụm theo khoảng cách, phù hợp kiểm tra cấu trúc phân cấp.

Gaussian Mixture: mô hình hóa dữ liệu như hỗn hợp nhiều phân phối Gaussian và gán cụm theo xác suất.

6.5 Deep Learning 5 lớp: Autoencoder + K-Means

Input của Autoencoder là đúng 8 topic shares, không đưa RFM vào quá trình tạo cụm để giữ khái niệm "interest" tách biệt với "customer value". Kiến trúc Input(8) -> ReLU(16) -> tanh Bottleneck(4) -> ReLU(16) -> Linear(8). Mạng học reconstruction bằng MSE trong 1.800 epochs. Sau đó K-Means k=5 chạy trên vector bottleneck 4

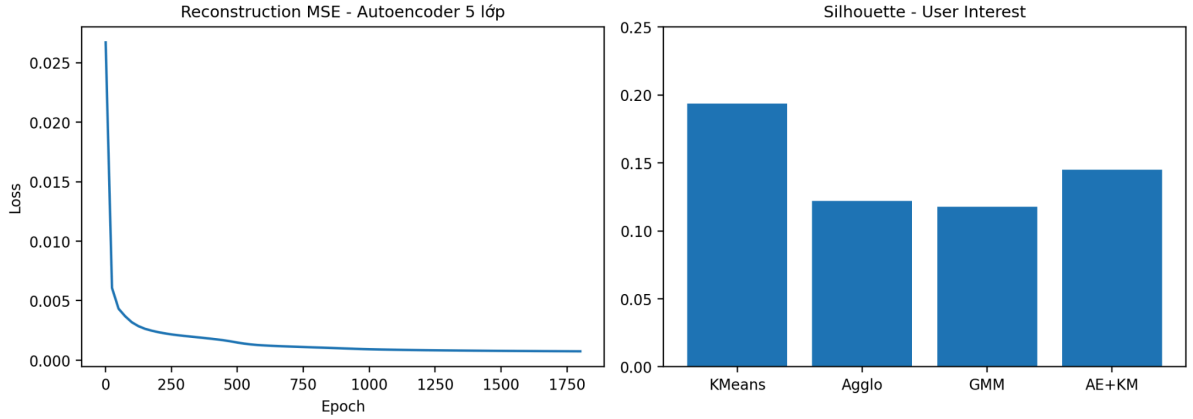
chiều. RFM chỉ được tính ở bước sau để mô tả mức độ hoạt động của từng cụm, không dùng để quyết định sở thích.



Hình 6.4. Trực quan PCA 2D của hồ sơ User Interest và K-Means k=5.

6.6 Benchmark clustering

Model	Silhouette ↑	DB ↓	CH ↑	Fit time
K-Means	0.1937	1.4307	871.9	0.201s
Agglomerative Clustering	0.1219	1.7039	688.0	0.381s
Gaussian Mixture	0.1178	2.0872	393.3	1.558s
NumPy DL 5-layer Autoencoder + K-Means	0.1451	1.8551	702.8	2.612s

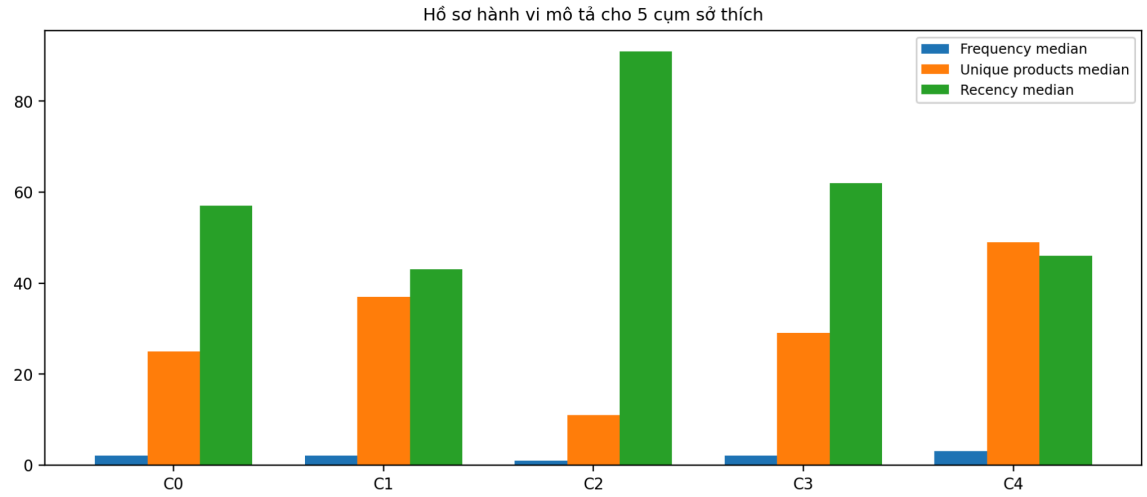


Hình 6.5. Reconstruction loss Autoencoder và benchmark Silhouette.

K-Means đạt Silhouette 0.1937 và là baseline mạnh nhất trong ba mô hình cổ điển ở k=5. Autoencoder + K-Means đạt 0.1451. DL không vượt K-Means trên metric này, nhưng reconstruction loss giảm xuống 0.000744, chứng tỏ bottleneck 4 chiều có khả năng tái tạo phần lớn cấu trúc topic-share. Kết quả này củng cố một thông điệp quan trọng: Deep Learning không mặc định tốt hơn mô hình đơn giản trên dữ liệu tabular/compositional nhỏ.

6.7 Năm nhóm User Interest và hồ sơ hành vi

Cụm	Users	Share	Recency	Frequency	Monetary	Unique products	Avg order
C0 - Trang trí ánh sáng & trái tim	653	15.1%	57	2	463	25	235
C1 - Vintage/Christmas & quà tặng	939	21.6%	43	2	717	37	321
C2 - Trang sức & thủy tinh	224	5.2%	91	1	344	11	210
C3 - Bộ sản phẩm/giấy & đồ nhà	567	13.1%	62	2	647	29	304
C4 - Hỗn hợp quà tặng - retro - decor	1955	45.1%	46	3	847	49	303



Hình 6.6. Hồ sơ hành vi mô tả của 5 cụm interest.

6.7.1 Cụm C0: Trang trí ánh sáng & trái tim

Cụm có 653 khách hàng (15.1% tổng user sạch). Ba topic trung bình nổi bật là T4 Đèn nến, trái tim và đồ treo trang trí (39.2%); T6 Vintage, Giáng sinh và quà tặng (12.9%); T7 Thủy tinh, trang sức và phụ kiện (10.7%). Median Recency=57 ngày, Frequency=2 invoice và Monetary=462.95. RFM ở đây chỉ là lớp mô tả sau phân cụm, giúp phân biệt một interest phổ biến nhưng ít hoạt động với một interest có mức mua cao.

Các sản phẩm có doanh thu cao trong cụm: WHITE HANGING HEART T-LIGHT HOLDER (39,273); ASSORTED COLOUR BIRD ORNAMENT (17,833); COLOUR GLASS. STAR T-LIGHT HOLDER (14,498); FAIRY CAKE FLANNEL ASSORTED COLOUR (13,366); RABBIT NIGHT LIGHT (11,548).

6.7.2 Cụm C1: Vintage/Christmas & quà tặng

Cụm có 939 khách hàng (21.6% tổng user sạch). Ba topic trung bình nổi bật là T6 Vintage, Giáng sinh và quà tặng (43.4%); T2 Retrospot đỏ, túi và đồ bếp (13.5%); T0 Bộ sản phẩm, giấy và phụ kiện nhà cửa (11.9%). Median Recency=43 ngày, Frequency=2 invoice và Monetary=717.45. RFM ở đây chỉ là lớp mô tả sau phân cụm, giúp phân biệt một interest phổ biến nhưng ít hoạt động với một interest có mức mua cao.

Các sản phẩm có doanh thu cao trong cụm: JUMBO BAG RED RETROSPOT (40,887); PAPER CHAIN KIT 50'S CHRISTMAS (22,747); JUMBO BAG VINTAGE DOILY (21,386); JUMBO BAG PINK POLKADOT (19,877); JUMBO BAG APPLES (18,790).

6.7.3 Cụm C2: Trang sức & thủy tinh

Cụm có 224 khách hàng (5.2% tổng user sạch). Ba topic trung bình nổi bật là T7 Thủy tinh, trang sức và phụ kiện (39.0%); T4 Đèn nến, trái tim và đồ treo trang trí (17.3%); T1 Hoa văn hồng, hoa và đồ dệt trang trí (11.1%). Median Recency=91 ngày, Frequency=1 invoice và Monetary=344.45. RFM ở đây chỉ là lớp mô tả sau phân cụm, giúp phân biệt một interest phổ biến nhưng ít hoạt động với một interest có mức mua cao.

Các sản phẩm có doanh thu cao trong cụm: MEDIUM CERAMIC TOP STORAGE JAR (77,326); PICNIC BASKET WICKER SMALL (40,596); BLACK RECORD COVER FRAME (28,278); ANTIQUE SILVER T-LIGHT GLASS (4,772); RECORD FRAME 7" SINGLE SIZE (3,953).

6.7.4 Cụm C3: Bộ sản phẩm/giấy & đồ nhà

Cụm có 567 khách hàng (13.1% tổng user sạch). Ba topic trung bình nổi bật là T0 Bộ sản phẩm, giấy và phụ kiện nhà cửa (32.6%); T6 Vintage, Giáng sinh và quà tặng (20.6%); T2 Retrospot đỏ, túi và đồ bếp (12.7%). Median Recency=62 ngày, Frequency=2 invoice và Monetary=646.68. RFM ở đây chỉ là lớp mô tả sau phân cụm, giúp phân biệt một interest phổ biến nhưng ít hoạt động với một interest có mức mua cao.

Các sản phẩm có doanh thu cao trong cụm: PAPER CRAFT , LITTLE BIRDIE (168,470); POSTAGE (21,282); CHILLI LIGHTS (16,119); REGENCY CAKESTAND 3 TIER (15,003); Manual (10,012).

6.7.5 Cụm C4: Hỗn hợp quà tặng - retro - decor

Cụm có 1,955 khách hàng (45.1% tổng user sạch). Ba topic trung bình nổi bật là T6 Vintage, Giáng sinh và quà tặng (18.9%); T2 Retrospot đỏ, túi và đồ bếp (16.6%); T4 Đèn nến, trái tim và đồ treo trang trí (13.1%). Median Recency=46 ngày, Frequency=3 invoice và Monetary=846.72. RFM ở đây chỉ là lớp mô tả sau phân cụm, giúp phân biệt một interest phổ biến nhưng ít hoạt động với một interest có mức mua cao.

Các sản phẩm có doanh thu cao trong cụm: REGENCY CAKESTAND 3 TIER (108,332); WHITE HANGING HEART T-LIGHT HOLDER (51,468); JUMBO BAG RED RETROSPOT (40,797); POSTAGE (40,243); PARTY BUNTING (40,155).

Ứng dụng thực tế của User Interest Discovery có thể là cá nhân hóa banner/sản phẩm đề xuất, chọn nội dung email theo chủ đề, tạo look-alike segment hoặc phân tích danh mục. Tuy nhiên các cụm ở đây là kết quả không giám sát; trước khi dùng cho chiến dịch thật cần A/B test để kiểm tra xem cá nhân hóa theo cụm có làm tăng CTR, conversion hoặc revenue hay không.

CHƯƠNG 7: SO SÁNH VÀ ĐÁNH GIÁ ĐA MÔ HÌNH

7.1 Diabetes - Classification

Model tốt nhất theo Macro F1 là Random Forest (500 trees). Random Forest/Decision Tree rất mạnh vì dữ liệu có nhiều ngưỡng xét nghiệm rõ ràng và chỉ 1.000 mẫu. DL 5 lớp vẫn đạt Macro F1 0.9329, cho thấy implementation NumPy học được representation có ý nghĩa nhưng không có lợi thế dữ liệu lớn để vượt ensemble tree.

7.2 Housing - Regression

Model tốt nhất theo R^2 là Linear Regression, R^2=0.6529. DL đạt R^2=0.6483. Với chỉ 545 dòng, mô hình tuyến tính vẫn cạnh tranh mạnh, trong khi cây đơn dễ có phương sai cao và mạng sâu dễ overfit nếu train quá lâu.

7.3 User Interest - Unsupervised

K-Means k=5 có Silhouette 0.1937, DB=1.4307; Autoencoder + K-Means có Silhouette 0.1451. Vì không có label interest thật, không thể dùng Accuracy để nói cụm nào "đúng". Đánh giá cần kết hợp metric hình học và khả năng diễn giải top terms/top products.

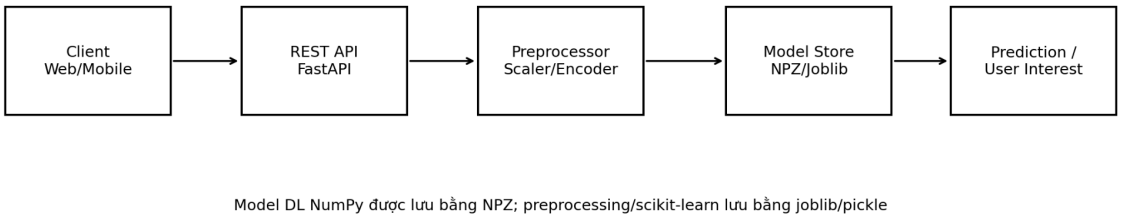
7.4 Trade-offs

Khía cạnh	Mô hình đơn giản	Tree/Ensemble	DL 5 lớp
Tốc độ	Nhanh nhất	Trung bình; RF tốn nhiều cây	Chậm hơn vì nhiều epoch NumPy
Khả năng diễn giải	Cao với linear/logistic	Tree dễ giải thích; RF khó hơn	Black-box hơn; cần phân tích representation
Dữ liệu nhỏ	Thường ổn định	Rất cạnh tranh trên tabular	Dễ overfit nếu không kiểm soát
Feature engineering	Phụ thuộc nhiều	Ít nhạy scaling	Có thể tự học biến đổi phi tuyến
Triển khai	Nhẹ	Mô hình lớn hơn	NPZ gọn nhưng cần đúng preprocessing

Không có một thuật toán thắng trên mọi task. Mục tiêu của Assignment 03 vì thế không nên chỉ là tìm số điểm cao nhất, mà là hiểu vì sao các mô hình khác nhau phản ứng khác nhau với kích thước mẫu, mất cân bằng lớp, feature representation và mục tiêu supervised/unsupervised.

CHƯƠNG 8: THIẾT KẾ TRIỂN KHAI HỆ THỐNG

8.1 Kiến trúc tổng thể



Hình 8.1. Kiến trúc triển khai đề xuất cho ba hệ thống.

Sau huấn luyện, StandardScaler/OneHotEncoder và các model scikit-learn có thể lưu bằng joblib. Mạng NumPy lưu trực tiếp W1-W4, b1-b4 vào NPZ. Backend FastAPI nạp các artifact một lần khi khởi động, nhận JSON từ client, validate schema, áp dụng đúng preprocessing đã fit ở Train, chạy forward pass và trả kết quả JSON.

8.2 API Diabetes

```
POST /diabetes/predict
{ "Gender":"F", "AGE":52, "Urea":5.0, "Cr":60, "HbA1c":7.2, "Chol":4.8,
"TG":2.0, "HDL":1.1, "LDL":2.6, "VLDL":0.9, "BMI":31.0 }
-> { "class":"Y", "probabilities":{"N":...,"P":...,"Y":...} }
```

API nên trả cả xác suất ba lớp thay vì chỉ label để client có thể hiển thị mức confidence. Kết quả chỉ mang tính demo học máy trên dataset của Assignment, không nên trình bày như chẩn đoán y tế được kiểm định.

8.3 API Housing

```
POST /housing/predict
{ "area":7420, "bedrooms":4, "bathrooms":2, "stories":3, "mainroad":"yes", ... }
-> { "predicted_price":  ... }
```

Backend phải dùng chính encoder/scaler đã được fit khi train. Nếu tự fit lại scaler trên một request hoặc đổi thứ tự cột one-hot, dự đoán sẽ sai dù trọng số mạng không đổi.

8.4 API User Interest

Có hai kiểu endpoint. (1) Offline segmentation: batch job định kỳ tính topic shares cho toàn bộ CustomerID và lưu cluster vào bảng CRM. (2) Online profile: nhận lịch sử giao dịch của một user, ánh xạ StockCode sang topic vector, tính revenue-weighted shares rồi gán centroid K-Means gần nhất. Vì TF-IDF/NMF học từ vocabulary tập huấn luyện, hệ thống cần chính sách xử lý sản phẩm mới và lịch retrain định kỳ.

CHƯƠNG 9: TÍNH TÁI LẬP VÀ TỔ CHỨC MÃ NGUỒN

9.1 Cấu trúc thư mục đề xuất

```
assignment_03/
  data/
    Dataset of Diabetes .csv
    Housing(1).csv
    data(1).csv
  src/
    numpy_nn.py
    diabetes_pipeline.py
    housing_pipeline.py
    user_interest_pipeline.py
  models/
    diabetes_5layer.npz
    housing_5layer.npz
    interest_autoencoder.npz
    preprocessors.joblib
  figures/
  api/
    main.py
  report/
    Assignment03_detailed.docx
  requirements.txt
  README.md
```

9.2 Reproducibility checklist

Python 3.x; NumPy, pandas, scikit-learn, matplotlib, python-docx.

np.random.seed(42) và random_state=42 tại các bước có ngẫu nhiên.

Split Diabetes/Housing giữ cố định như trong báo cáo.

Không fit StandardScaler/OneHotEncoder trên Test.

data(1).csv phải đọc với encoding latin1/cp1252; UTF-8 trực tiếp gây UnicodeDecodeError trong môi trường thực nghiệm.

Các rule làm sạch E-commerce phải giữ nguyên để số customer/topic profiles tái lập.

Ghi lại architecture, learning rate, epochs, L2 và class weighting của DL.

9.3 Thông số tái lập chính

Task	DL architecture	Loss	Optimizer	LR	Epochs
Diabetes	11-64-32-16-3	Weighted CE + L2	Adam NumPy	0.001	400

Housing	13-64-32-16-1	MSE + L2	Adam NumPy	0.0005	200
User Interest	8-16-4-16-8 Autoencoder	Reconstruction MSE + L2	Adam NumPy	0.002	1800

A

CHƯƠNG 10: KẾT LUẬN, HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN

10.1 Kết luận chính

Diabetes: sau làm sạch nhãn và cân bằng loss, mô hình tốt nhất theo Macro F1 là Random Forest (500 trees); DL 5 lớp đạt Macro F1 0.9329.

Housing: Linear Regression đạt R^2 0.6529; DL 5 lớp đạt R^2 0.6483 và cho thấy cần kiểm soát epoch để tránh overfit.

E-commerce: User Interest được xây dựng trực tiếp từ Description bằng TF-IDF + NMF thành 8 topic shares. K-Means k=5 tạo năm nhóm interest có thể diễn giải bằng top terms và top products.

Deep Learning 5 lớp được hiện thực đầy đủ bằng NumPy với forward, loss, backpropagation và Adam; kết quả thực nghiệm cho thấy DL là một công cụ, không phải lựa chọn mặc định tốt nhất cho mọi tabular dataset.

10.2 Hạn chế

Diabetes chỉ có 1.000 mẫu và lớp P rất ít; một split Test 200 mẫu khiến metric lớp hiếm có phương sai cao.

Housing chỉ 545 mẫu; chưa dùng cross-validation hoặc tìm kiếm hyperparameter hệ thống.

Topic names E-commerce là diễn giải từ NMF top terms, không phải nhãn danh mục do nhà bán lẻ cung cấp.

K=5 được chọn vì cân bằng metric và khả năng vận hành, không phải cực đại Silhouette toàn cục.

Autoencoder được huấn luyện full-batch NumPy để minh họa cơ chế; chưa có mini-batch, dropout hoặc GPU acceleration.

10.3 Hướng phát triển

Dùng Stratified K-Fold cho Diabetes và K-Fold cho Housing để báo cáo mean ± std.

Thêm probability calibration, feature importance/SHAP cho bài toán supervised.

E-commerce: học embeddings sản phẩm/user từ sequence giao dịch, thử Word2Vec/Transformer hoặc collaborative filtering.

Đánh giá User Interest bằng A/B testing downstream thay vì chỉ cluster metrics.

Đóng gói pipeline bằng FastAPI + Docker, version model và lưu metadata train để kiểm soát reproducibility.

PHỤ LỤC A: DATA DICTIONARY

A.1 Diabetes

Cột	Vai trò	Xử lý

ID	Định danh bản ghi	Loại khỏi X
No_Pation	Định danh bệnh nhân	Loại khỏi X
Gender	Category	strip + upper + one-hot
AGE, Urea, Cr, HbA1c, Chol, TG, HDL, LDL, VLDL, BMI	Numeric features	StandardScaler trên Train
CLASS	Target N/P/Y	strip whitespace, LabelEncoder cho DL

A.2 Housing

Nhóm cột	Cột	Xử lý
Target	price	Không scale với ML; scale y_train cho DL
Numeric	area, bedrooms, bathrooms, stories, parking	StandardScaler
Binary category	mainroad, guestroom, basement, hotwaterheating, airconditioning, prefarea	OneHotEncoder(drop=first)
Nominal	furnishingstatus	OneHotEncoder(drop=first)

A.3 E-commerce

Cột	Ý nghĩa sử dụng
InvoiceNo	Xác định hóa đơn; prefix C dùng nhận biết cancellation
StockCode	Khóa sản phẩm để gắn topic
Description	Nguồn văn bản để TF-IDF + NMF trích interest
Quantity	Lọc >0; tham gia Revenue
InvoiceDate	Tính Recency và khoảng thời gian
UnitPrice	Lọc >0; tham gia Revenue
CustomerID	Đơn vị user; dòng thiếu bị loại trong user profiling
Country	Mô tả thị trường; không dùng để tạo interest cluster

PHỤ LỤC B: CẤU HÌNH MÔ HÌNH VÀ MÃ HÀM CỐT LÕI

B.1 Cấu hình 3 mô hình cơ bản

```
Diabetes:
  LogisticRegression(class_weight='balanced', max_iter=3000)
  DecisionTreeClassifier(max_depth=6, class_weight='balanced')
```

```
  RandomForestClassifier(n_estimators=500, max_depth=12,
class_weight='balanced_subsample')

Housing:
  LinearRegression()
  DecisionTreeRegressor(max_depth=6)
  RandomForestRegressor(n_estimators=1000, max_features=0.8)

User Interest:
  KMeans(n_clusters=5, n_init=50)
  AgglomerativeClustering(n_clusters=5)
  GaussianMixture(n_components=5, n_init=10)
```

B.2 Pseudocode Training Loop DL

```
for epoch in range(epochs):
    cache = forward(X, params)
    loss = compute_loss(cache, y) + L2(params)
    grads = backward(cache, y, params)
    params = adam_update(params, grads)

# classifier: Softmax + weighted CE
# regressor: Linear + MSE
# autoencoder: reconstruction MSE
```